

Análisis de conglomerados

Clustering, perfiles penitenciarios y aprendizaje no supervisado

Noam López Villanes

17 de mayo de 2026

Tabla de contenidos

1	Objetivo de la sesión	1
2	Preparación	2
3	Importar y conocer la base	2
4	Exploración inicial	4
5	Preparar variables para clustering	7
6	Elegir el número de clústeres	8
7	K-means	9
8	Clustering jerárquico	13
9	DBSCAN	16
10	PAM con variables mixtas	18
11	Comparar métodos	20
12	Ejercicios para seguir practicando	21

1. Objetivo de la sesión

En esta sesión trabajaremos con una base de población penitenciaria para introducir el **análisis de conglomerados**. A diferencia de una regresión o una prueba de hipótesis, aquí no partimos

de una variable dependiente. El objetivo es encontrar grupos de casos que se parezcan entre sí según ciertas características observadas.

1. Preparar variables para un análisis de clustering.
2. Distinguir variables numéricas, categóricas y mixtas.
3. Escalar variables para que sean comparables.
4. Aplicar k-means e interpretar centroides.
5. Comparar resultados con clustering jerárquico y DBSCAN.
6. Usar PAM con distancia de Gower para variables mixtas.
7. Traducir los clústeres en perfiles interpretables.

2. Preparación

Si ejecutas este documento por partes, corre primero los chunks de **Instalar paquetes**, **Activar paquetes** y **Ubicar archivos**. Los tres están ocultos en el redenzado final, pero esos bloques crean los paquetes, funciones y rutas que usan los demás chunks.

3. Importar y conocer la base

¿Qué información trae la base de población penitenciaria?

```
pope <- read_delim(
  archivo_pope,
  delim = ";",
  locale = locale(encoding = "Latin1"),
  show_col_types = FALSE
) |>
clean_names() |>
mutate(
  sexo = str_to_sentence(sexo),
  delito_generico = str_squish(delito_generico),
  delito_especifico = str_squish(delito_especifico),
  situacion_juridica = str_to_sentence(str_squish(situacion_juridica)),
  departamento = str_to_title(departamento),
  edad = as.numeric(edad),
  no_de_ingresos = as.numeric(no_de_ingresos)
)

glimpse(pope)
```

Rows: 97,605

Columns: 17

```
$ id          <dbl> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15~
$ no_de_ingresos <dbl> 3, 1, 1, 1, 1, 1, 1, 3, 1, 1, 1, 1, 1, 2, 1, 1, 1~
$ delito_generico <chr> "DELITOS CONTRA EL PATRIMONIO", "DELITOS CONTRA L~
$ delito_especifico <chr> "ROBO AGRAVADO", "HOMICIDIO CALIFICADO - ASESINAT~
$ situacion_juridica <chr> "Sentenciado", "Sentenciado", "Sentenciado", "Pro~
$ edad         <dbl> 30, 28, 23, 38, 19, 43, 37, 39, 37, 31, 31, 21, 4~
$ sexo         <chr> "Masculino", "Masculino", "Masculino", "Masculino~
$ pais         <chr> "PERÚ", "PERÚ", "COLOMBIA", "PERÚ", "PERÚ", "PERÚ~
$ estado_civil <chr> "SOLTERO", "SOLTERO", "CONVIVIENTE", "CONVIVIENTE~
$ grado_de_instruccion <chr> "PRIMARIA COMP.", "SECUNDARIA COMP.", "SECUNDARIA~
$ ocupacion_generico <chr> "OFICIOS", "OFICIOS", "OFICIOS", "OFICIOS", "OFIC~
$ ocupacion_especifico <chr> "OBREROS", "OBREROS", "OTROS OFICIOS", "OBREROS",~
$ nombre_del_penal <chr> "E.P. DE TUMBES", "E.P. DE TUMBES", "E.P. DE TUMB~
$ departamento <chr> "Tumbes", "Tumbes", "Tumbes", "Tumbes", "Tumbes",~
$ oficina_regional <chr> "Norte - Chiclayo", "Norte - Chiclayo", "Norte - ~
$ mes          <chr> "JUNIO", "JUNIO", "JUNIO", "JUNIO", "JUNIO", "JUN~
$ continente   <chr> "América", "América", "América", "América", "Amér~
```

La base registra personas privadas de libertad y contiene variables sociodemográficas, jurídicas y penitenciarias. Para clustering debemos elegir variables que tengan sentido sustantivo y que puedan compararse técnicamente.

¿Cuántos casos tenemos y qué rangos observamos?

```
pope |>
  summarise(
    personas = n(),
    edad_minima = min(edad, na.rm = TRUE),
    edad_maxima = max(edad, na.rm = TRUE),
    maximo_ingresos = max(no_de_ingresos, na.rm = TRUE),
    delitos_genericos = n_distinct(delito_generico),
    penales = n_distinct(nombre_del_penal),
    departamentos = n_distinct(departamento)
  )
```

A tibble: 1 x 7


```
  personas edad_minima edad_maxima maximo_ingresos delitos_genericos penales
    <int>      <dbl>      <dbl>          <dbl>          <int>    <int>
1    97605         18         95            21            25      69
# i 1 more variable: departamentos <int>
```

Esta primera revisión ayuda a evitar errores de interpretación. Por ejemplo, edad y número de ingresos son numéricas, pero sexo, delito genérico y situación jurídica son categóricas.

4. Exploración inicial

¿Cómo se distribuye la edad de la población penitenciaria?


```
pope |>
  ggplot(aes(x = edad)) +
  geom_histogram(binwidth = 5, fill = "#577590", color = "white", boundary = 0) +
  scale_x_continuous(breaks = seq(15, 100, by = 10)) +
  labs(
    title = "Distribución de edad",
    subtitle = "Población penitenciaria registrada en la base POPE",
    x = "Edad",
    y = "Personas"
  ) +
  tema_sesion()
```



La edad es una variable numérica de razón. En clustering, una variable numérica con escala amplia puede dominar el cálculo de distancias si no la estandarizamos.

¿Qué delitos genéricos son más frecuentes?

```
pope |>
  count(delito_generico, sort = TRUE) |>
  slice_head(n = 10) |>
  ggplot(aes(x = n, y = reorder(delito_generico, n))) +
  geom_col(fill = "#ef476f", width = 0.7) +
  geom_text(aes(label = comma(n)), hjust = -0.12, size = 3.2) +
  scale_x_continuous(labels = comma_format(), expand = expansion(mult = c(0, 0.12))) +
  labs(
    title = "Delitos genéricos más frecuentes",
    x = "Personas",
    y = NULL
  ) +
  tema_sesion()
```




Las categorías más frecuentes son relevantes porque pueden aparecer como rasgos distintivos de algunos clústeres. Sin embargo, no conviene meter demasiadas categorías raras en una primera versión del ejercicio.

¿Cómo se relacionan edad y número de ingresos?

```
set.seed(123)
pope_muestra <- pope |>
  filter(!is.na(edad), !is.na(no_de_ingresos)) |>
  slice_sample(n = min(10000, nrow(pope |> filter(!is.na(edad), !is.na(no_de_ingresos)))))

pope_muestra |>
  ggplot(aes(x = edad, y = no_de_ingresos)) +
  geom_jitter(alpha = 0.18, width = 0.25, height = 0.12, color = "#3a86ff") +
  scale_y_continuous(breaks = pretty_breaks()) +
  labs(
    title = "Edad y número de ingresos",
    subtitle = "Muestra aleatoria para facilitar la visualización",
    x = "Edad",
    y = "Número de ingresos"
  ) +
  tema_sesion()
```



Esta relación es útil para introducir la idea de distancia: dos personas pueden parecerse porque tienen edad e historial de ingresos similares, aunque sus delitos o situación jurídica sean distintos.

5. Preparar variables para clustering

¿Por qué debemos escalar las variables numéricas?

```
datos_cluster <- pope |>
  transmute(
    id,
    edad,
    ingresos = no_de_ingresos,
    sexo,
    delito_generico,
    situacion_juridica,
    departamento,
    nombre_del_penal
  ) |>
  filter(
    !is.na(edad),
    !is.na(ingresos),
    edad >= 18,
    ingresos >= 1
  )

variables_numericas <- datos_cluster |>
  select(edad, ingresos)

variables_escaladas <- variables_numericas |>
  scale() |>
  as_tibble()

summary(variables_numericas)
```

	edad	ingresos
Min.	:18.00	Min. : 1.000
1st Qu.	:29.00	1st Qu.: 1.000
Median	:36.00	Median : 1.000
Mean	:38.48	Mean : 1.414
3rd Qu.	:46.00	3rd Qu.: 1.000
Max.	:95.00	Max. :21.000

```
summary(variables_escaladas)
```

edad	ingresos
Min. : -1.7014	Min. : -0.42
1st Qu.: -0.7876	1st Qu.: -0.42
Median : -0.2061	Median : -0.42
Mean : 0.0000	Mean : 0.00
3rd Qu.: 0.6246	3rd Qu.: -0.42
Max. : 4.6953	Max. : 19.86

Escalar significa restar la media y dividir entre la desviación estándar. Después de escalar, edad e ingresos quedan en unidades comparables. Esto es clave para métodos como k-means, que usan distancias.


6. Elegir el número de clústeres

¿Cuántos grupos deberíamos buscar?

```
set.seed(123)
k_posibles <- 1:8

suma_cuadrados <- map_dfr(k_posibles, function(k) {
  modelo <- kmeans(variables_escaladas, centers = k, nstart = 20)
  tibble(k = k, wss = modelo$tot.withinss)
})

suma_cuadrados |>
  ggplot(aes(x = k, y = wss)) +
  geom_line(color = "#577590", linewidth = 0.9) +
  geom_point(size = 2.8, color = "#577590") +
  scale_x_continuous(breaks = k_posibles) +
  scale_y_continuous(labels = comma_format()) +
  labs(
    title = "Método del codo",
    subtitle = "Busca un punto donde agregar más clústeres deja de reducir mucho la variación",
    x = "Número de clústeres",
    y = "Suma de cuadrados dentro de clústeres"
  ) +
  tema_sesion()
```

El método del codo no da una respuesta automática. Ayuda a justificar una decisión. En clase usaremos $k = 4$ porque permite diferenciar perfiles sin volver la interpretación demasiado fragmentada.

7. K-means

¿Qué perfiles aparecen si agrupamos por edad e ingresos?

```
set.seed(123)
modelo_kmeans <- kmeans(variables_escaladas, centers = 4, nstart = 25)

datos_kmeans <- datos_cluster |>
  mutate(cluster_kmeans = factor(modelo_kmeans$cluster))

datos_kmeans |>
  group_by(cluster_kmeans) |>
  summarise(
    personas = n(),
    porcentaje = personas / nrow(datos_kmeans),
    edad_promedio = mean(edad, na.rm = TRUE),
```

```

    ingresos_promedio = mean(ingresos, na.rm = TRUE),
    .groups = "drop"
)

```


A tibble: 4 x 5

	cluster_kmeans	personas	porcentaje	edad_promedio	ingresos_promedio
	<fct>	<int>	<dbl>	<dbl>	<dbl>
1	1	54657	0.560	30.4	1.09
2	2	1980	0.0203	50.5	6.24
3	3	14014	0.144	40.8	2.59
4	4	26954	0.276	52.8	1.11

```

datos_kmeans |>
  count(cluster_kmeans) |>
  mutate(porcentaje = n / sum(n)) |>
  ggplot(aes(x = cluster_kmeans, y = porcentaje, fill = cluster_kmeans)) +
  geom_col(width = 0.7, show.legend = FALSE) +
  geom_text(aes(label = percent(porcentaje, accuracy = 0.1)), vjust = -0.35, size = 3.4) +
  scale_y_continuous(labels = percent_format(), expand = expansion(mult = c(0, 0.12))) +
  scale_fill_paletteer_d("ggthemes::Tableau_10") +
  labs(
    title = "Tamaño de los clústeres k-means",
    x = "Clúster",
    y = "Porcentaje"
  ) +
  tema_sesion()

```



El tamaño de cada clúster nos dice si el modelo está produciendo grupos relativamente equilibrados o si separa casos muy específicos.

¿Dónde se ubican los clústeres en el espacio edad-ingresos?


```
centroides <- datos_kmeans |>
  group_by(cluster_kmeans) |>
  summarise(
    edad = mean(edad, na.rm = TRUE),
    ingresos = mean(ingresos, na.rm = TRUE),
    .groups = "drop"
  )

datos_kmeans |>
  slice_sample(n = min(12000, nrow(datos_kmeans))) |>
  ggplot(aes(x = edad, y = ingresos, color = cluster_kmeans)) +
  geom_jitter(alpha = 0.22, width = 0.25, height = 0.12) +
  geom_point(
    data = centroides,
    aes(x = edad, y = ingresos),
    inherit.aes = FALSE,
    shape = 4,
  )
```

```

    stroke = 1.4,
    size = 5,
    color = "black"
  ) +
  scale_color_paletteer_d("ggthemes::Tableau_10") +
  labs(
    title = "Clústeres k-means según edad e ingresos",
    subtitle = "Las cruces negras son centroides",
    x = "Edad",
    y = "Número de ingresos",
    color = "Clúster"
  ) +
  tema_sesion()

```



Los centroides muestran el promedio de edad e ingresos dentro de cada grupo. Esa comparación permite describir los perfiles con más precisión que el gráfico de dispersión por sí solo.

¿Cómo podemos describir cada clúster?

```

perfil_kmeans <- datos_kmeans |>
  group_by(cluster_kmeans) |>

```

```

summarise(
  personas = n(),
  edad_promedio = mean(edad, na.rm = TRUE),
  ingresos_promedio = mean(ingresos, na.rm = TRUE),
  porcentaje_mujeres = mean(sexo == "Femenino", na.rm = TRUE),
  delito_mas_frecuente = names(sort(table(delito_generico), decreasing = TRUE))[1],
  situacion_mas_frecuente = names(sort(table(situacion_juridica), decreasing = TRUE))[1],
  .groups = "drop"
) |>
mutate(
  porcentaje_mujeres = percent(porcentaje_mujeres, accuracy = 0.1)
)

perfil_kmeans

```

```

# A tibble: 4 x 7
  cluster_kmeans personas edad_promedio ingresos_promedio porcentaje_mujeres
  <fct>          <int>      <dbl>          <dbl> <chr>
1 1              54657      30.4          1.09 5.5%
2 2               1980      50.5          6.24 2.5%
3 3             14014      40.8          2.59 2.9%
4 4             26954      52.8          1.11 6.0%
# i 2 more variables: delito_mas_frecuente <chr>, situacion_mas_frecuente <chr>

```

Esta tabla convierte el resultado técnico en perfiles interpretables. Un clúster puede representar personas jóvenes con pocos ingresos, personas mayores con varios ingresos, u otros patrones según los datos.

```

write_csv(
  datos_kmeans,
  file.path(ruta_resultados, "pope_clusters_kmeans.csv")
)

```

8. Clustering jerárquico

¿Qué pasa si no fijamos centroides sino que unimos casos por similitud?

```


set.seed(123)
muestra_hc <- datos_cluster |>
  slice_sample(n = min(1200, nrow(datos_cluster)))

variables_hc <- muestra_hc |>
  select(edad, ingresos) |>
  scale()

distancia_hc <- dist(variables_hc)
modelo_hc <- hclust(distancia_hc, method = "complete")

plot(
  modelo_hc,
  labels = FALSE,
  main = "Dendrograma jerárquico",
  xlab = "",
  sub = ""
)
rect.hclust(modelo_hc, k = 4, border = "#ef476f")

```




El dendrograma muestra un proceso de agrupamiento. Al cortar el árbol en cuatro ramas,

obtenemos cuatro grupos. La ventaja es que permite ver anidamientos; la desventaja es que puede volverse pesado con bases grandes.

```
muestra_hc <- muestra_hc |>
  mutate(cluster_hc = factor(cutree(modelo_hc, k = 4)))

muestra_hc |>
  ggplot(aes(x = edad, y = ingresos, color = cluster_hc)) +
  geom_jitter(alpha = 0.5, width = 0.25, height = 0.12) +
  scale_color_paletteer_d("ggthemes::Tableau_10") +
  labs(
    title = "Clústeres jerárquicos",
    subtitle = "Muestra aleatoria usada para reducir el costo computacional",
    x = "Edad",
    y = "Número de ingresos",
    color = "Clúster"
  ) +
  tema_sesion()
```



Este método sirve para discutir que no hay una única forma correcta de agrupar. Cada algoritmo define la similitud de manera distinta.


9. DBSCAN

¿Podemos identificar grupos densos y casos atípicos?

```
set.seed(123)
muestra_dbscan <- datos_cluster |>
  slice_sample(n = min(6000, nrow(datos_cluster)))

variables_dbscan <- muestra_dbscan |>
  select(edad, ingresos) |>
  scale()

kNNdistplot(variables_dbscan, k = 4)
abline(h = 0.20, col = "#ef476f", lwd = 2)
```



El gráfico ordena las distancias al cuarto vecino más cercano. El tramo donde la curva empieza a subir con más fuerza sirve como referencia para escoger `eps`; aquí usamos 0.20 como valor inicial para discutir cuántos casos quedan como ruido y cuántos forman clústeres.


```

modelo_dbscan <- dbscan(variables_dbscan, eps = 0.20, minPts = 5)

muestra_dbscan <- muestra_dbscan |>
  mutate(
    cluster_dbscan = factor(
      modelo_dbscan$cluster,
      levels = sort(unique(modelo_dbscan$cluster))
    )
  )

muestra_dbscan |>
  count(cluster_dbscan) |>
  mutate(
    tipo = if_else(cluster_dbscan == "0", "Ruido", "Clúster"),
    porcentaje = n / sum(n)
  )

```

```

# A tibble: 11 x 4
  cluster_dbscan      n tipo      porcentaje
  <fct>          <int> <chr>         <dbl>
1 0              53 Ruido      0.00883
2 1            4497 Clúster    0.750
3 2             944 Clúster    0.157
4 3             289 Clúster    0.0482
5 4              7 Clúster    0.00117
6 5             21 Clúster    0.0035
7 6            110 Clúster    0.0183
8 7             44 Clúster    0.00733
9 8             17 Clúster    0.00283
10 9            13 Clúster    0.00217
11 10            5 Clúster    0.000833

```

```

muestra_dbscan |>
  ggplot(aes(x = edad, y = ingresos, color = cluster_dbscan)) +
  geom_jitter(alpha = 0.45, width = 0.25, height = 0.12) +
  scale_color_paletteer_d("ggthemes::Tableau_20") +
  labs(
    title = "Resultados DBSCAN",
    subtitle = "El clúster 0 corresponde a puntos clasificados como ruido",
    x = "Edad",
    y = "Número de ingresos",
  )

```


```

    color = "Grupo"
  ) +
  tema_sesion()

```

Resultados DBSCAN

El clúster 0 corresponde a puntos clasificados como ruido



DBSCAN es útil cuando esperamos grupos por densidad y casos atípicos. En cambio, k-means fuerza a que todos los casos pertenezcan a algún clúster.

10. PAM con variables mixtas

¿Qué hacemos si queremos combinar variables numéricas y categóricas?

```

set.seed(123)
muestra_pam <- datos_cluster |>
  mutate(
    sexo = factor(sexo),
    delito_generico = fct_lump_n(factor(delito_generico), n = 6),
    situacion_juridica = factor(situacion_juridica)
  ) |>
  slice_sample(n = min(2500, nrow(datos_cluster))) |>

```

```

select(edad, ingresos, sexo, delito_generico, situacion_juridica)

distancia_gower <- daisy(muestra_pam, metric = "gower")
modelo_pam <- pam(distancia_gower, k = 4)

datos_pam <- muestra_pam |>
  mutate(cluster_pam = factor(modelo_pam$clustering))

tibble(
  cluster_pam = factor(seq_along(modelo_pam$id.med)),
  observacion_medoide = modelo_pam$id.med,
  personas = as.integer(modelo_pam$clusinfo[, "size"]),
  diametro = modelo_pam$clusinfo[, "diameter"],
  separacion = modelo_pam$clusinfo[, "separation"]
)

```

```

# A tibble: 4 x 5
  cluster_pam observacion_medoide personas diametro separacion
  <fct>          <int>      <int>      <dbl>      <dbl>
1 1              72        662      0.807      0.00274
2 2             375        440      0.858      0.00274
3 3             123        661      0.668      0.00274
4 4             124        737      0.635      0.00274

```

La distancia de Gower permite combinar variables numéricas y categóricas. Por eso PAM es una buena alternativa cuando el perfil no depende solo de edad e ingresos.

```

perfil_pam <- datos_pam |>
  group_by(cluster_pam) |>
  summarise(
    personas = n(),
    edad_promedio = mean(edad, na.rm = TRUE),
    ingresos_promedio = mean(ingresos, na.rm = TRUE),
    sexo_mas_frecuente = names(sort(table(sexo), decreasing = TRUE))[1],
    delito_mas_frecuente = names(sort(table(delito_generico), decreasing = TRUE))[1],
    situacion_mas_frecuente = names(sort(table(situacion_juridica), decreasing = TRUE))[1],
    .groups = "drop"
  )

perfil_pam

```

```
# A tibble: 4 x 7
  cluster_pam personas edad_promedio ingresos_promedio sexo_mas_frecuente
  <fct>         <int>         <dbl>         <dbl> <chr>
1 1             662          48.0          1.25 Masculino
2 2             440          42.1          1.49 Masculino
3 3             661          34.6          1.64 Masculino
4 4             737          31.9          1.37 Masculino
# i 2 more variables: delito_mas_frecuente <chr>, situacion_mas_frecuente <chr>
```

La tabla permite leer cada clúster como un perfil: combina edad, ingresos, sexo, delito y situación jurídica. Conviene nombrar los grupos a partir de esos rasgos dominantes y revisar si las diferencias son claras antes de usar los perfiles en una interpretación sustantiva.

11. Comparar métodos

¿Qué método usaríamos según la pregunta?

Método	Tipo de variables	Pregunta que responde mejor	Cuidado principal
K-means	Numéricas escaladas	¿Qué grupos aparecen si todos los casos deben pertenecer a un clúster?	Requiere elegir k ; sensible a escala y valores atípicos.
Jerárquico	Numéricas escaladas o distancias	¿Cómo se van uniendo los casos según similitud?	Costoso con bases grandes; depende del método de enlace.
DBSCAN	Numéricas escaladas	¿Hay zonas densas y casos de ruido?	Sensible a eps y minPts .
PAM + Gower	Variables mixtas	¿Qué perfiles aparecen usando numéricas y categóricas?	Puede ser costoso; conviene trabajar con muestras o bases medianas.

La elección del método depende de la pregunta, el tipo de variables, el tamaño de la base y la facilidad para explicar los resultados a una audiencia no técnica.

12. Ejercicios para seguir practicando

1. Repite k-means con $k = 3$ y $k = 5$. ¿Cambian mucho los perfiles?
2. Incluye otra variable numérica o transforma edad en grupos. ¿Qué se gana y qué se pierde?
3. Cambia el valor de `eps` en DBSCAN y observa cuántos casos pasan a ruido.
4. Usa PAM con otro conjunto de variables categóricas.
5. Exporta la base con clústeres y calcula qué delitos predominan en cada grupo.

Estos ejercicios pueden apoyarse en el Posit Assistant de RStudio para revisar errores, pedir explicaciones de funciones y proponer mejoras al código.