

Análisis descriptivo de registros municipales

RENAMU, serenazgo, videovigilancia e intervenciones municipales

Noam López Villanes

15 de mayo de 2026

Tabla de contenidos

1	Objetivo de la sesión	2
2	Preparación	3
3	Importación	3
3.1	Revisar el separador del archivo	3
3.2	Importar RENAMU correctamente	3
4	Estructura de la base	4
4.1	Dimensiones generales	4
4.2	Seleccionar variables de seguridad	5
4.3	Valores perdidos	6
4.4	Duplicados por ubigeo	8
5	Cobertura del servicio de serenazgo	8
5.1	Serenazgo al 31 de marzo de 2025	8
5.2	Cobertura por departamento	10
6	Efectivos de serenazgo	13
6.1	Distribución general	13
6.2	Valores atípicos	14
6.3	Composición por sexo	16
7	Equipamiento e infraestructura	18
7.1	Variables principales de equipamiento	18
7.2	Cámaras de videovigilancia	21

8	Intervenciones registradas por serenazgo	24
8.1	Total por tipo de intervención	24
8.2	Intervenciones por departamento	27
8.3	Municipalidades con más intervenciones	29
9	Primer cruce descriptivo	31
9.1	Serenazgo, cámaras e intervenciones	31
10	Galería aplicada de visualizaciones	33
10.1	Histograma y densidad	33
10.2	Violin y beeswarm	34
10.3	Ridgeline por departamento	35
10.4	Lollipop de ranking	37
10.5	Barras agrupadas y apiladas	38
10.6	Bubble plot interactivo	41
10.7	Heatmap de intervenciones	43
10.8	Correlograma de indicadores	44
10.9	Dispersión y densidad 2D	46
10.10	Treemap de intervenciones	48
10.11	Heatmap de recursos categóricos	50
10.12	Base complementaria de celulares	51
10.13	Serie temporal con archivo complementario	54
11	Diccionario mínimo de trabajo	56
12	Exportar resultados	58
13	Ejercicios para seguir practicando	60

1. Objetivo de la sesión

En esta sesión trabajaremos con registros municipales de seguridad ciudadana a partir de la RENAMU 2025. El objetivo es aprender a producir un análisis descriptivo univariado ordenado:

1. Importar correctamente una base separada por punto y coma.
2. Revisar estructura, dimensiones, nombres de variables y valores perdidos.
3. Seleccionar variables municipales vinculadas a seguridad ciudadana.
4. Calcular frecuencias, porcentajes, medidas de tendencia central y dispersión.
5. Identificar valores atípicos en conteos municipales.
6. Visualizar distribuciones de serenazgo, videovigilancia e intervenciones.
7. Exportar bases resumidas para ejercicios posteriores.

2. Preparación

Si ejecutas este documento por partes, corre primero los chunks de **Instalar paquetes**, **Activar paquetes** y **Ubicar archivos**. Los tres están ocultos en el redenzado final, pero esos bloques crean los paquetes, funciones y rutas que usan los demás chunks

Esta versión coloca todos los archivos en una sola carpeta, con nombres cortos y sin tildes, para evitar problemas al descargar materiales desde Paideia. El análisis usará `renamu2025.csv`; el diccionario `dict_renamu2025.pdf` sirve para interpretar los códigos de variables.

3. Importación

3.1. Revisar el separador del archivo

```
renamu_lectura_incorrecta <- read_csv(  
  # read_csv() asume comas, pero este archivo viene separado por punto y coma.  
  file.path(ruta_renamu, "renamu2025.csv"),  
  n_max = 5,  
  show_col_types = FALSE  
)  
  
ncol(renamu_lectura_incorrecta)
```

```
[1] 1
```

Cuando una base aparece como una sola columna, no necesariamente está dañada. Muchas veces el problema es el separador: coma, punto y coma, tabulador u otro carácter.

3.2. Importar RENAMU correctamente

```
cargar_renamu_original()  
  
glimpse(renamu_original[, 1:12])
```

```
Rows: 1,891
```

```
Columns: 12
```

```
$ ano      <chr> "2025", "2025", "2025", "2025", "2025", "2025", "2025", "~
```

```

$ idmunici      <chr> "010101", "010102", "010103", "010104", "010105", "010106~
$ ccdd         <chr> "01", "01", "01", "01", "01", "01", "01", "01", "01", "01~
$ ccpp         <chr> "01", "01", "01", "01", "01", "01", "01", "01", "01", "01~
$ ccdi         <chr> "01", "02", "03", "04", "05", "06", "07", "08", "09", "10~
$ ubigeo       <chr> "010101", "010102", "010103", "010104", "010105", "010106~
$ departamento <chr> "AMAZONAS", "AMAZONAS", "AMAZONAS", "AMAZONAS", "AMAZONAS~
$ provincia    <chr> "CHACHAPOYAS", "CHACHAPOYAS", "CHACHAPOYAS", "CHACHAPOYAS~
$ distrito     <chr> "CHACHAPOYAS", "ASUNCION", "BALSAS", "CHETO", "CHILIQUN"~
$ tipomuni     <chr> "1", "2", "2", "2", "2", "2", "2", "2", "2", "2", "2", "2~
$ vfi          <chr> "1", "1", "1", "1", "1", "1", "1", "1", "1", "1", "1", "1~
$ p04_1        <chr> "2", "3", "1", "2", "3", "2", "3", "2", "1", "2", "2", "2~

```

La base se importa correctamente con `read_delim(delim = ";")`. Mantener inicialmente las columnas como texto ayuda a controlar códigos como `#¡NULO!` antes de convertir variables numéricas.

4. Estructura de la base

4.1. Dimensiones generales

```

resumen_base <- tibble(
  base = "RENAMU 2025",
  filas = nrow(renamu_original),
  columnas = ncol(renamu_original)
)

```

```
resumen_base
```

```

# A tibble: 1 x 3
  base      filas columnas
  <chr>    <int>   <int>
1 RENAMU 2025  1891    1388

```

La RENAMU tiene una fila por municipalidad y muchas columnas porque recoge información de distintos módulos municipales. Para esta sesión no usaremos todo el cuestionario, sino el bloque de seguridad ciudadana.

4.2. Seleccionar variables de seguridad

```
preparar_renamu_seguridad()
```

```
renamu_seguridad |>
  select(
    ano,
    ubigeo,
    departamento,
    provincia,
    distrito,
    tipo_municipalidad,
    serenazgo_2025,
    p69_2_t,
    tiene_camaras,
    p70a_7_1,
    tiene_central_videovigilancia,
    total_intervenciones
  ) |>
  head(10)
```

```
# A tibble: 10 x 12
```

	ano	ubigeo	departamento	provincia	distrito	tipo_municipalidad
	<dbl>	<chr>	<chr>	<chr>	<chr>	<chr>
1	2025	010101	AMAZONAS	CHACHAPOYAS	CHACHAPOYAS	Provincial
2	2025	010102	AMAZONAS	CHACHAPOYAS	ASUNCION	Distrital
3	2025	010103	AMAZONAS	CHACHAPOYAS	BALSAS	Distrital
4	2025	010104	AMAZONAS	CHACHAPOYAS	CHETO	Distrital
5	2025	010105	AMAZONAS	CHACHAPOYAS	CHILIQVIN	Distrital
6	2025	010106	AMAZONAS	CHACHAPOYAS	CHUQUIBAMBA	Distrital
7	2025	010107	AMAZONAS	CHACHAPOYAS	GRANADA	Distrital
8	2025	010108	AMAZONAS	CHACHAPOYAS	HUANCAS	Distrital
9	2025	010109	AMAZONAS	CHACHAPOYAS	LA JALCA	Distrital
10	2025	010110	AMAZONAS	CHACHAPOYAS	LEIMBAMBA	Distrital

```
# i 6 more variables: serenazgo_2025 <chr>, p69_2_t <dbl>, tiene_camaras <chr>,
# p70a_7_1 <dbl>, tiene_central_videovigilancia <chr>,
# total_intervenciones <dbl>
```

Trabajar con un subconjunto permite concentrar la sesión en preguntas sustantivas: si el municipio brinda serenazgo, con cuántos efectivos cuenta, qué equipamiento tiene y cuántas intervenciones registra.

4.3. Valores perdidos

```
preparar_renamu_seguridad()

perdidos_seguridad <- renamu_seguridad |>
  summarise(
    across(
      c(p69_2_t, p70a_1_1, p70a_7_1, p70a_10_1, p71a_1, total_intervenciones),
      ~ sum(is.na(.x))
    )
  ) |>
  pivot_longer(
    cols = everything(),
    names_to = "variable",
    values_to = "perdidos"
  ) |>
  mutate(porcentaje = perdidos / nrow(renamu_seguridad))

perdidos_seguridad
```

```
# A tibble: 6 x 3
  variable      perdidos porcentaje
  <chr>          <int>     <dbl>
1 p69_2_t           626     0.331
2 p70a_1_1          913     0.483
3 p70a_7_1        1257     0.665
4 p70a_10_1        1395     0.738
5 p71a_1          1382     0.731
6 total_intervenciones      0      0
```


Los valores perdidos no siempre son errores. En este caso, varios conteos aparecen vacíos porque la municipalidad respondió que no tiene el servicio, equipo o intervención correspondiente.

```
perdidos_seguridad |>
  ggplot(aes(x = reorder(variable, porcentaje), y = porcentaje)) +
  geom_segment(
    aes(xend = variable, y = 0, yend = porcentaje),
    color = "#b8b8b8",
    linewidth = 0.8
  ) +
```

```

geom_point(size = 4, color = "#577590") +
geom_text(
  aes(label = percent(porcentaje, accuracy = 0.1)),
  hjust = -0.15,
  size = 3.2
) +
coord_flip() +
scale_y_continuous(labels = percent_format(), limits = c(0, 1)) +
labs(
  title = "Valores perdidos en variables seleccionadas",
  x = NULL,
  y = "Porcentaje de municipalidades"
) +
tema_sesion()

```



El gráfico permite distinguir variables casi completas de variables condicionadas por filtros del cuestionario. En encuestas o registros administrativos, el patrón de pérdida suele depender de la lógica de preguntas.

4.4. Duplicados por ubigeo

```
duplicados_ubigeo <- renamu_seguridad |>
  count(ubigeo, sort = TRUE) |>
  filter(n > 1)

duplicados_ubigeo
```

```
# A tibble: 0 x 2
# i 2 variables: ubigeo <chr>, n <int>
```

Si esta tabla queda vacía, cada municipalidad aparece una sola vez por **ubigeo**. Esa revisión es básica antes de resumir información territorial.

5. Cobertura del servicio de serenazgo

5.1. Serenazgo al 31 de marzo de 2025

```
preparar_renamu_seguridad()

cobertura_serenazgo <- renamu_seguridad |>
  count(serenazgo_2025, name = "municipalidades") |>
  mutate(porcentaje = municipalidades / sum(municipalidades))

cobertura_serenazgo
```

```
# A tibble: 2 x 3
  serenazgo_2025 municipalidades porcentaje
  <chr>          <int>         <dbl>
1 No             626         0.331
2 Sí            1265         0.669
```


Esta tabla responde una primera pregunta descriptiva: cuántas municipalidades declaran brindar serenazgo al 31 de marzo de 2025.


```

cobertura_serenazgo |>
  filter(serenazgo_2025 != "Sin dato") |>
  mutate(
    bloques = round(porcentaje * 100),
    estado = str_c(
      serenazgo_2025,
      " (",
      percent(porcentaje, accuracy = 0.1),
      ")"
    )
  ) |>
  uncount(bloques) |>
  mutate(
    celda = row_number(),
    columna = (celda - 1) %% 10,
    fila = (celda - 1) %/% 10
  ) |>
  ggplot(aes(x = columna, y = fila, fill = estado)) +
  geom_tile(
    color = "white",
    linewidth = 0.6,
    width = 0.95,
    height = 0.95
  ) +
  coord_equal() +
  scale_y_reverse() +
  scale_fill_manual(values = c("#b56576", "#2f6f73")) +
  labs(
    title = "Municipalidades que brindan serenazgo",
    subtitle = "RENAMU 2025",
    fill = NULL
  ) +
  theme_void(base_size = 11) +
  theme(legend.position = "bottom")

```

Municipalidades que brindan serenazgo
RENAMU 2025



La visualización muestra la cobertura general del servicio. Es una lectura univariada porque analiza una sola variable categórica.

5.2. Cobertura por departamento

```
serenazgo_departamento <- renamu_seguridad |>
  group_by(departamento) |>
  summarise(
    municipalidades = n(),
    con_serenazgo = sum(p69_2 == 1, na.rm = TRUE),
    porcentaje_serenazgo = con_serenazgo / municipalidades,
    .groups = "drop"
  ) |>
  arrange(desc(porcentaje_serenazgo))

serenazgo_departamento
```

A tibble: 25 x 4


	departamento	municipalidades	con_serenazgo	porcentaje_serenazgo
	<chr>	<int>	<int>	<dbl>
1	CALLAO	7	7	1
2	UCAYALI	19	19	1
3	PUNO	110	108	0.982
4	ICA	43	41	0.953
5	CUSCO	116	109	0.940
6	MADRE DE DIOS	11	10	0.909
7	HUANUCO	84	75	0.893
8	PASCO	29	25	0.862
9	TACNA	28	24	0.857
10	TUMBES	13	11	0.846

i 15 more rows

Aunque el foco de la sesión es descriptivo, agrupar por departamento ayuda a mostrar heterogeneidad territorial sin pasar todavía a modelos explicativos.

```
serenazgo_departamento |>
  mutate(departamento = reorder(departamento, porcentaje_serenazgo)) |>
  ggplot(aes(x = porcentaje_serenazgo, y = departamento)) +
  geom_segment(
    aes(x = 0, xend = porcentaje_serenazgo, yend = departamento),
    color = "#d8d8d8",
    linewidth = 0.7
  ) +
  geom_point(aes(color = porcentaje_serenazgo), size = 3.2) +
  geom_text(
    aes(label = percent(porcentaje_serenazgo, accuracy = 1)),
    hjust = -0.18,
    size = 2.7
  ) +
  scale_x_continuous(labels = percent_format(), limits = c(0, 1.08)) +
  scale_color_paletteer_c("viridis::mako", labels = percent_format()) +
  labs(
    title = "Cobertura de serenazgo por departamento",
    subtitle = "Porcentaje de municipalidades que reportan serenazgo",
    x = "Cobertura",
    y = NULL,
    fill = "Cobertura"
  ) +
  tema_sesion() +
  theme()
```

```
axis.text.y = element_text(size = 7.4),
legend.position = "none"
)
```



El gráfico ordenado facilita comparar departamentos sin apretar las etiquetas. En análisis descriptivo, ordenar categorías suele ser más útil que dejarlas alfabéticamente.

6. Efectivos de serenazgo

6.1. Distribución general

```
efectivos_serenazgo <- renamu_seguridad |>
  filter(p69_2 == 1) |>
  summarise(
    municipalidades = n(),
    minimo = min(p69_2_t, na.rm = TRUE),
    q1 = quantile(p69_2_t, 0.25, na.rm = TRUE),
    mediana = median(p69_2_t, na.rm = TRUE),
    promedio = mean(p69_2_t, na.rm = TRUE),
    q3 = quantile(p69_2_t, 0.75, na.rm = TRUE),
    maximo = max(p69_2_t, na.rm = TRUE)
  )
```


efectivos_serenazgo

A tibble: 1 x 7

	municipalidades	minimo	q1	mediana	promedio	q3	maximo
	<int>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	1265	1	3	7	33.5	20	1534

La media puede ser mucho mayor que la mediana cuando pocas municipalidades concentran muchos efectivos. Por eso conviene reportar varias medidas, no solo el promedio.

```
renamu_seguridad |>
  filter(p69_2 == 1, !is.na(p69_2_t)) |>
  ggplot(aes(x = p69_2_t)) +
  geom_histogram(binwidth = 25, fill = "#577590", color = "white") +
  scale_x_continuous(labels = comma_format()) +
  labs(
    title = "Distribución de efectivos de serenazgo",
    subtitle = "Municipalidades que brindan serenazgo",
    x = "Efectivos de serenazgo",
    y = "Número de municipalidades"
  ) +
  tema_sesion()
```



La distribución está concentrada en valores bajos y tiene una cola larga. Este patrón es común en registros territoriales: pocas unidades grandes pueden dominar la escala.

6.2. Valores atípicos

```
limites_efectivos <- renamu_seguridad |>
  filter(p69_2 == 1, !is.na(p69_2_t)) |>
  summarise(
    q1 = quantile(p69_2_t, 0.25),
    q3 = quantile(p69_2_t, 0.75),
    iqr = IQR(p69_2_t),
    limite_superior = q3 + 1.5 * iqr
  )

municipalidades_atipicas <- renamu_seguridad |>
  filter(p69_2 == 1, p69_2_t > limites_efectivos$limite_superior) |>
  arrange(desc(p69_2_t)) |>
  select(departamento, provincia, distrito, p69_2_t)
```

```
limites_efectivos
```

```
# A tibble: 1 x 4
  q1    q3   iqr limite_superior
<dbl> <dbl> <dbl>         <dbl>
1     3    20    17           45.5
```


```
municipalidades_atipicas |> head(15)
```

```
# A tibble: 15 x 4
  departamento provincia distrito      p69_2_t
  <chr>         <chr>    <chr>      <dbl>
1 LIMA          LIMA    SANTIAGO DE SURCO    1534
2 LIMA          LIMA    SAN JUAN DE LURIGANCHO 1427
3 LIMA          LIMA    MIRAFLORES          997
4 LIMA          LIMA    LIMA                989
5 LIMA          LIMA    SAN ISIDRO           960
6 LIMA          LIMA    SAN BORJA            900
7 LIMA          LIMA    PUENTE PIEDRA        761
8 LA LIBERTAD   TRUJILLO TRUJILLO            740
9 LIMA          LIMA    JESUS MARIA          723
10 LIMA          LIMA    LURIN                655
11 TACNA        TACNA    TACNA                625
12 LIMA          LIMA    COMAS                601
13 LIMA          LIMA    ATE                  600
14 CALLAO       CALLAO    CALLAO               590
15 LIMA          LIMA    SAN MARTIN DE PORRES  514
```

Un valor atípico no debe borrarse automáticamente. En conteos municipales puede representar una capital provincial, un distrito grande o una diferencia real de capacidad institucional.

```
renamu_seguridad |>
  filter(p69_2 == 1, !is.na(p69_2_t)) |>
  ggplot(aes(x = tipo_municipalidad, y = p69_2_t, fill = tipo_municipalidad)) +
  geom_boxplot(show.legend = FALSE, outlier.alpha = 0.45) +
  scale_y_continuous(labels = comma_format()) +
  labs(
    title = "Efectivos de serenazgo según tipo de municipalidad",
    x = NULL,
    y = "Efectivos"
```

```
) +  
tema_sesion()
```



El boxplot permite comparar distribución, mediana y valores extremos entre municipalidades provinciales y distritales. Es útil cuando la variable numérica tiene mucha dispersión.

6.3. Composición por sexo

```
efectivos_sexo <- renamu_seguridad |>  
  filter(p69_2 == 1) |>  
  summarise(  
    hombres = sum(p69_2_h, na.rm = TRUE),  
    mujeres = sum(p69_2_m, na.rm = TRUE)  
  ) |>  
  pivot_longer(  
    cols = everything(),  
    names_to = "sexo",
```



```

    values_to = "efectivos"
  ) |>
  mutate(porcentaje = efectivos / sum(efectivos))

efectivos_sexo

```

```

# A tibble: 2 x 3
  sexo      efectivos porcentaje
<chr>      <dbl>      <dbl>
1 hombres    33207      0.784
2 mujeres     9126      0.216

```


Esta tabla muestra la composición agregada del personal de serenazgo por sexo. La interpretación debe hacerse con cuidado porque no es una tasa por municipalidad, sino un total acumulado.

```

efectivos_sexo |>
  ggplot(aes(x = 2, y = porcentaje, fill = sexo)) +
  geom_col(color = "white", width = 1) +
  coord_polar(theta = "y") +
  xlim(0.5, 2.5) +
  geom_text(
    aes(label = percent(porcentaje, accuracy = 0.1)),
    position = position_stack(vjust = 0.5),
    size = 4
  ) +
  scale_fill_manual(values = c("hombres" = "#577590", "mujeres" = "#b56576")) +
  labs(
    title = "Composición del serenazgo por sexo",
    fill = NULL
  ) +
  theme_void(base_size = 11) +
  theme(
    plot.title = element_text(size = 13, hjust = 0.5, margin = margin(b = 10)),
    legend.position = "bottom"
  )

```

Composición del serenazgo por sexo



El gráfico permite observar rápidamente la composición del personal. Para profundizar, podría calcularse el porcentaje de mujeres dentro de cada municipalidad.

7. Equipamiento e infraestructura

7.1. Variables principales de equipamiento

```
equipamiento_resumen <- renamu_seguridad |>
  summarise(
    auto_o_camioneta = sum(p70_1 == 1, na.rm = TRUE),
    radio_comunicador = sum(p70_6 == 1, na.rm = TRUE),
    camara_videovigilancia = sum(p70_7 == 1, na.rm = TRUE),
    central_videovigilancia = sum(p70_10 == 1, na.rm = TRUE),
    chaleco_antibalas = sum(p70_13 == 1, na.rm = TRUE),
    municipalidades = n()
  ) |>
  pivot_longer(
```

```

    cols = -municipalidades,
    names_to = "recurso",
    values_to = "municipalidades_con_recurso"
  ) |>
  mutate(
    porcentaje = municipalidades_con_recurso / municipalidades,
    recurso = str_replace_all(recurso, "_", " ")
  ) |>
  arrange(desc(porcentaje))

equipamiento_resumen

```

```

# A tibble: 5 x 4
  municipalidades recurso      municipalidades_con_recurso porcentaje
      <int> <chr>                <int>          <dbl>
1      1891 auto o camioneta          978          0.517
2      1891 camara videovigilancia    634          0.335
3      1891 radio comunicador        531          0.281
4      1891 central videovigilancia   496          0.262
5      1891 chaleco antibalas        329          0.174

```

Esta tabla compara la presencia de distintos recursos municipales. La lectura sigue siendo univariada por recurso, pero el formato permite ponerlos en una misma vista.

```


equipamiento_resumen |>
  mutate(
    recurso = str_to_sentence(recurso),
    no_tiene = 1 - porcentaje
  ) |>
  select(recurso, tiene = porcentaje, no_tiene) |>
  pivot_longer(
    cols = c(tiene, no_tiene),
    names_to = "estado",
    values_to = "porcentaje"
  ) |>
  mutate(
    color_texto = if_else(porcentaje < 0.45, "white", "black")
  ) |>
  ggplot(aes(x = estado, y = reorder(recurso, porcentaje), fill = porcentaje)) +
  geom_tile(color = "white", linewidth = 0.7) +
  geom_text(

```

```

aes(label = percent(porcentaje, accuracy = 0.1), color = color_texto),
size = 3.2
) +
scale_x_discrete(labels = c("no_tiene" = "No tiene", "tiene" = "Tiene")) +
scale_fill_paletteer_c("viridis::mako", labels = percent_format()) +
scale_color_identity() +
labs(
  title = "Municipalidades con recursos para serenazgo",
  subtitle = "Matriz de presencia y ausencia de recursos",
  x = NULL,
  y = NULL,
  fill = "Porcentaje"
) +
tema_sesion()

```



Ordenar recursos por porcentaje ayuda a identificar qué capacidades están más extendidas y cuáles son menos frecuentes.

7.2. Cámaras de videovigilancia

```
camaras_resumen <- renamu_seguridad |>
  filter(p70_7 == 1) |>
  summarise(
    municipalidades_con_camaras = n(),
    total_camaras = sum(p70a_7_1, na.rm = TRUE),
    camaras_operativas = sum(p70a_7_2, na.rm = TRUE),
    camaras_no_operativas = sum(p70a_7_3, na.rm = TRUE),
    camaras_integradas_pnp = sum(p70a_7_4, na.rm = TRUE),
    porcentaje_operativas = camaras_operativas / total_camaras,
    porcentaje_integradas_pnp = camaras_integradas_pnp / camaras_operativas
  )

camaras_resumen
```

```
# A tibble: 1 x 7
  municipalidades_con_c~1 total_camaras camaras_operativas camaras_no_operativas
          <int>          <dbl>          <dbl>          <dbl>
1           634        23461        19737        3724
# i abbreviated name: 1: municipalidades_con_camaras
# i 3 more variables: camaras_integradas_pnp <dbl>,
#   porcentaje_operativas <dbl>, porcentaje_integradas_pnp <dbl>
```

No basta con saber si una municipalidad tiene cámaras. Para gestión de seguridad, interesa cuántas están operativas y cuántas están integradas a la PNP.

```
camaras_departamento <- renamu_seguridad |>
  group_by(departamento) |>
  summarise(
    municipalidades = n(),
    con_camaras = sum(p70_7 == 1, na.rm = TRUE),
    total_camaras = sum(p70a_7_1, na.rm = TRUE),
    camaras_operativas = sum(p70a_7_2, na.rm = TRUE),
    camaras_no_operativas = sum(p70a_7_3, na.rm = TRUE),
    .groups = "drop"
  ) |>
  mutate(
    porcentaje_con_camaras = con_camaras / municipalidades,
    porcentaje_operativas = camaras_operativas / total_camaras
  ) |>
```

```

arrange(desc(total_camaras))

camaras_departamento

# A tibble: 25 x 8
  departamento municipalidades con_camaras total_camaras camaras_operativas
  <chr>          <int>      <int>      <dbl>      <dbl>
1 LIMA           171        90      10475      9484
2 AREQUIPA       109        51       2347      1861
3 CALLAO         7         7       1192       884
4 CUSCO          116        59       1165       982
5 LA LIBERTAD    84         35       1153       736
6 ANCASH         166        58       807        676
7 ICA            43         26       679        589
8 JUNIN          124        51       677        525
9 PIURA         65         20       619        444
10 AYACUCHO      124        31       499        384
# i 15 more rows
# i 3 more variables: camaras_no_operativas <dbl>,
# porcentaje_con_camaras <dbl>, porcentaje_operativas <dbl>

```

Este resumen muestra tanto cobertura municipal como volumen de cámaras. Un departamento puede tener muchas cámaras por pocas municipalidades grandes, o una cobertura más distribuida.

```


camaras_departamento |>
  slice_max(total_camaras, n = 15) |>
  mutate(
    departamento = reorder(departamento, total_camaras)
  ) |>
  select(departamento, camaras_operativas, camaras_no_operativas) |>
  pivot_longer(
    cols = c(camaras_operativas, camaras_no_operativas),
    names_to = "estado",
    values_to = "camaras"
  ) |>
  ggplot(aes(x = departamento, y = camaras, fill = estado)) +
  geom_col(width = 0.75) +
  coord_flip() +
  scale_y_continuous(labels = comma_format()) +
  scale_fill_manual(

```

```

breaks = c("camaras_operativas", "camaras_no_operativas"),
values = c(
  "camaras_operativas" = "#2f6f73",
  "camaras_no_operativas" = "#b56576"
),
labels = c("Operativas", "No operativas")
) +
labs(
  title = "Cámaras de videovigilancia por estado",
  subtitle = "Departamentos con mayor número total de cámaras",
  x = NULL,
  y = "Número de cámaras",
  fill = NULL
) +
tema_sesion()

```



El ranking permite ubicar la concentración del equipamiento. En este gráfico, el tramo verde corresponde a cámaras operativas y el tramo rosa a cámaras no operativas. La lectura principal

es doble: dónde se concentra el volumen de cámaras y qué parte de ese equipamiento está fuera de operación.

8. Intervenciones registradas por serenazgo

8.1. Total por tipo de intervención

```
intervenciones_larga <- renamu_seguridad |>
  select(
    ubigeo,
    departamento,
    provincia,
    distrito,
    robo_transeuntes = p71a_1,
    robo_domicilio = p71a_2,
    robo_vehiculos = p71a_3,
    robo_autopartes = p71a_4,
    robo_establecimientos = p71a_5,
    alcohol_via_publica = p71a_6,
    consumo_drogas = p71a_7,
    accidentes_transito = p71a_8,
    comercio_informal = p71a_9,
    violencia_familiar = p71a_10,
    pandillaje = p71a_11,
    otro = p71a_12
  ) |>
  pivot_longer(
    cols = -c(ubigeo, departamento, provincia, distrito),
    names_to = "tipo_intervencion",
    values_to = "intervenciones"
  )

intervenciones_tipo <- intervenciones_larga |>
  group_by(tipo_intervencion) |>
  summarise(
    intervenciones = sum(intervenciones, na.rm = TRUE),
    municipalidades_con_registro = sum(intervenciones > 0, na.rm = TRUE),
    .groups = "drop"
  ) |>
  mutate(porcentaje = intervenciones / sum(intervenciones)) |>
```



```

arrange(desc(intervenciones))

intervenciones_tipo

# A tibble: 12 x 4
  tipo_intervencion      intervenciones municipalidades_con_registro porcentaje
  <chr>                  <dbl>                <int>         <dbl>
1 alcohol_via_publica    573834                1      0.461
2 consumo_drogas         311336                1      0.250
3 comercio_informal      162510                1      0.130
4 accidentes_transito     70422                1      0.0565
5 violencia_familiar     48336                1      0.0388
6 robo_transeuntes       28713                1      0.0230
7 pandillaje            12001                1      0.00963
8 otro                  10942                1      0.00878
9 robo_domicilio        10461                1      0.00840
10 robo_vehiculos         6738                1      0.00541
11 robo_establecimientos  5986                1      0.00480
12 robo_autopartes       4759                1      0.00382

```

Esta tabla permite identificar qué tipos de intervención concentran más registros de serenazgo. El total depende tanto de la incidencia del problema como de la capacidad municipal de registrar intervenciones.

```

intervenciones_tipo |>
  mutate(
    etiqueta = str_to_sentence(str_replace_all(tipo_intervencion, "_", " "))
  ) |>
  ggplot(aes(
    area = intervenciones,
    fill = tipo_intervencion,
    label = etiqueta
  )) +
  treemapify::geom_treemap(color = "white", linewidth = 0.8) +
  treemapify::geom_treemap_text(
    color = "white",
    place = "center",
    grow = TRUE,
    reflow = TRUE,
    min.size = 6
  ) +

```

```
scale_fill_paletteer_d("ggsci::category20_d3", guide = "none") +
labs(
  title = "Intervenciones registradas por tipo",
  subtitle = "El tamaño representa el volumen de intervenciones"
) +
tema_sesion() +
theme(
  axis.text = element_blank(),
  axis.title = element_blank(),
  panel.grid = element_blank()
)
```



La visualización ayuda a priorizar categorías para discusión. En esta etapa no afirmamos causalidad: solo describimos el volumen registrado.

8.2. Intervenciones por departamento

```
intervenciones_departamento <- renamu_seguridad |>
  group_by(departamento) |>
  summarise(
    municipalidades = n(),
    total_intervenciones = sum(total_intervenciones, na.rm = TRUE),
    promedio_intervenciones = mean(total_intervenciones, na.rm = TRUE),
    mediana_intervenciones = median(total_intervenciones, na.rm = TRUE),
    .groups = "drop"
  ) |>
  arrange(desc(total_intervenciones))

intervenciones_departamento
```

```
# A tibble: 25 x 5
  departamento municipalidades total_intervenciones promedio_intervenciones
  <chr>          <int>          <dbl>          <dbl>
1 LIMA           171          726911         726911
2 AREQUIPA       109          106082         106082
3 CALLAO         7           102572         102572
4 LA LIBERTAD    84           49403          49403
5 JUNIN         124           49302          49302
6 ANCASH        166           22795          22795
7 CUSCO         116           20474          20474
8 PIURA        65           19057          19057
9 HUANUCO       84           17800          17800
10 TACNA        28           17595          17595
# i 15 more rows
# i 1 more variable: mediana_intervenciones <dbl>
```


El total departamental muestra volumen agregado, mientras que promedio y mediana resumen el comportamiento municipal. Conviene mirar ambas escalas.

```
intervenciones_departamento |>
  slice_max(total_intervenciones, n = 15) |>
  mutate(departamento = reorder(departamento, total_intervenciones)) |>
  ggplot(aes(x = total_intervenciones, y = departamento)) +
  geom_segment(
    aes(x = 0, xend = total_intervenciones, yend = departamento),
```

```

    color = "#b8b8b8",
    linewidth = 0.8
) +
geom_point(size = 3.2, color = "#577590") +
scale_x_continuous(labels = comma_format()) +
labs(
  title = "Departamentos con más intervenciones de serenazgo",
  x = "Intervenciones registradas",
  y = NULL
) +
tema_sesion()

```



Los departamentos con mayor volumen pueden reflejar mayor actividad, mayor población, mejor registro o una combinación de esas condiciones.

8.3. Municipalidades con más intervenciones


```
renamu_seguridad |>
  arrange(desc(total_intervenciones)) |>
  select(
    departamento,
    provincia,
    distrito,
    tipo_municipalidad,
    total_intervenciones
  ) |>
  head(20)
```

A tibble: 20 x 5

	departamento	provincia	distrito	tipo_municipalidad	total_intervenciones
	<chr>	<chr>	<chr>	<chr>	<dbl>
1	LIMA	LIMA	SANTIAGO DE S~	Distrital	84082
2	LIMA	LIMA	SAN JUAN DE L~	Distrital	79929
3	CALLAO	CALLAO	VENTANILLA	Distrital	71413
4	LIMA	LIMA	LA MOLINA	Distrital	58456
5	LIMA	LIMA	SAN MARTIN DE~	Distrital	54635
6	LIMA	LIMA	LIMA	Provincial	53259
7	LIMA	LIMA	LOS OLIVOS	Distrital	42286
8	LIMA	LIMA	LA VICTORIA	Distrital	40041
9	LIMA	LIMA	CARABAYLLO	Distrital	37386
10	LIMA	LIMA	COMAS	Distrital	36753
11	AREQUIPA	AREQUIPA	AREQUIPA	Provincial	24736
12	LIMA	LIMA	SANTA ANITA	Distrital	19939
13	LIMA	LIMA	VILLA EL SALV~	Distrital	19077
14	LIMA	LIMA	SURQUILLO	Distrital	18904
15	LA LIBERTAD	TRUJILLO	VICTOR LARCO ~	Distrital	18841
16	JUNIN	HUANCAYO	EL TAMBO	Distrital	18460
17	LA LIBERTAD	TRUJILLO	TRUJILLO	Provincial	15173
18	LIMA	LIMA	SAN LUIS	Distrital	14489
19	LIMA	LIMA	LINCE	Distrital	14354
20	CALLAO	CALLAO	CALLAO	Provincial	14242

Revisar los casos extremos permite detectar municipalidades influyentes. Antes de graficar o modelar, conviene saber qué unidades explican buena parte del total.

```
renamu_seguridad |>
  filter(total_intervenciones > 0) |>
  ggplot(aes(x = total_intervenciones)) +
  geom_histogram(bins = 40, fill = "#b56576", color = "white") +
  scale_x_log10(labels = comma_format()) +
  labs(
    title = "Distribución de intervenciones municipales",
    subtitle = "Escala logarítmica para observar mejor la cola de la distribución",
    x = "Intervenciones registradas",
    y = "Número de municipalidades"
  ) +
  tema_sesion()
```



La escala logarítmica es útil cuando hay mucha concentración. No cambia los datos; solo facilita observar valores pequeños y grandes en el mismo gráfico.

9. Primer cruce descriptivo

9.1. Serenazgo, cámaras e intervenciones

```
cruce_capacidad_intervenciones <- renamu_seguridad |>
  mutate(
    grupo_camaras = case_when(
      p70_7 == 1 ~ "Tiene cámaras",
      p70_7 == 2 ~ "No tiene cámaras",
      TRUE ~ "Sin dato"
    )
  ) |>
  group_by(grupo_camaras) |>
  summarise(
    municipalidades = n(),
    promedio_intervenciones = mean(total_intervenciones, na.rm = TRUE),
    mediana_intervenciones = median(total_intervenciones, na.rm = TRUE),
    .groups = "drop"
  )

cruce_capacidad_intervenciones
```

```
# A tibble: 2 x 4
  grupo_camaras      municipalidades promedio_intervencio~1 mediana_intervenciones
  <chr>              <int>              <dbl>              <dbl>
1 No tiene cámaras      1257              49.0              2
2 Tiene cámaras         634             1868.             57
# i abbreviated name: 1: promedio_intervenciones
```


Este cruce sigue siendo descriptivo: compara intervenciones según disponibilidad de cámaras. No prueba que las cámaras causen más o menos intervenciones.

```
renamu_seguridad |>
  filter(p70_7 %in% c(1, 2), total_intervenciones > 0) |>
  mutate(
    grupo_camaras = if_else(p70_7 == 1, "Tiene cámaras", "No tiene cámaras")
  ) |>
  ggplot(aes(
    x = grupo_camaras,
    y = total_intervenciones,
```

```

    fill = grupo_camaras
  )) +
  geom_boxplot(show.legend = FALSE, outlier.alpha = 0.35) +
  scale_y_log10(labels = comma_format()) +
  labs(
    title = "Intervenciones según disponibilidad de cámaras",
    x = NULL,
    y = "Intervenciones registradas"
  ) +
  tema_sesion()

```



La comparación sugiere diferencias de distribución entre municipalidades con y sin cámaras. Para interpretarla mejor harían falta controles por población, urbanidad y capacidad administrativa.

10. Galería aplicada de visualizaciones

Esta sección usa varias familias de gráficos como una caja de herramientas. La pregunta no es “qué gráfico se ve mejor”, sino qué forma visual ayuda a entender mejor una variable, una comparación o una relación.

10.1. Histograma y densidad

Pregunta: ¿la mayoría de municipalidades tiene pocos o muchos efectivos de serenazgo?


```
preparar_renamu_seguridad()

datos_efectivos <- renamu_seguridad |>
  filter(p69_2 == 1, !is.na(p69_2_t), p69_2_t > 0)

grafico_histograma <- datos_efectivos |>
  ggplot(aes(x = p69_2_t)) +
  geom_histogram(bins = 35, fill = "#5b8e7d", color = "white") +
  scale_x_log10(labels = comma_format()) +
  labs(
    title = "Histograma",
    subtitle = "Frecuencia de municipalidades",
    x = "Efectivos de serenazgo",
    y = "Municipalidades"
  ) +
  tema_sesion()

grafico_densidad <- datos_efectivos |>
  ggplot(aes(x = p69_2_t)) +
  geom_density(fill = "#f4a261", alpha = 0.65, color = "#9c6644") +
  scale_x_log10(labels = comma_format()) +
  labs(
    title = "Densidad",
    subtitle = "Forma suavizada de la distribución",
    x = "Efectivos de serenazgo",
    y = "Densidad"
  ) +
  tema_sesion()

grafico_histograma + grafico_densidad
```




El histograma muestra conteos por intervalos; la densidad ayuda a ver la forma general de la distribución. En ambos usamos escala logarítmica porque hay pocas municipalidades con muchos efectivos.

10.2. Violin y beeswarm

Pregunta: ¿las municipalidades provinciales y distritales tienen distribuciones parecidas de efectivos?

```
datos_efectivos |>
  filter(p69_2_t <= quantile(p69_2_t, 0.98, na.rm = TRUE)) |>
  ggplot(aes(x = tipo_municipalidad, y = p69_2_t, fill = tipo_municipalidad)) +
  geom_violin(alpha = 0.6, show.legend = FALSE, trim = FALSE) +
  ggbeeswarm::geom_quasirandom(
    width = 0.18,
    alpha = 0.35,
    size = 1.2,
    show.legend = FALSE
  ) +
```

```
scale_fill_paletteer_d("MetBrewer::Hiroshige") +
scale_y_continuous(labels = comma_format()) +
labs(
  title = "Violin + beeswarm de efectivos de serenazgo",
  subtitle = "Se excluye el 2% superior para evitar que la cola oculte el patrón central",
  x = NULL,
  y = "Efectivos"
) +
tema_sesion()
```



El violin permite comparar la forma de la distribución; el beeswarm muestra cada municipalidad como un punto. Esta combinación evita esconder los datos detrás de una sola caja.

10.3. Ridgeline por departamento


Pregunta: ¿en qué departamentos los efectivos se concentran en pocas municipalidades y en cuáles se distribuyen más?

```

departamentos_top_efectivos <- datos_efectivos |>
  group_by(departamento) |>
  summarise(total_efectivos = sum(p69_2_t, na.rm = TRUE), .groups = "drop") |>
  slice_max(total_efectivos, n = 10)

datos_efectivos |>
  semi_join(departamentos_top_efectivos, by = "departamento") |>
  filter(p69_2_t > 0) |>
  ggplot(aes(
    x = p69_2_t,
    y = reorder(departamento, p69_2_t),
    fill = after_stat(x)
  )) +
  ggthemes::geom_density_ridges_gradient(
    scale = 1.7,
    rel_min_height = 0.01,
    alpha = 0.85
  ) +
  scale_x_log10(labels = comma_format()) +
  scale_fill_paletteer_c("viridis::mako", guide = "none") +
  labs(
    title = "Ridgeline de efectivos de serenazgo",
    subtitle = "Departamentos con mayor número total de efectivos",
    x = "Efectivos por municipalidad",
    y = NULL
  ) +
  tema_sesion()

```



El ridgeline sirve para comparar distribuciones entre varios grupos sin multiplicar demasiados gráficos. Aquí ayuda a ver si un departamento concentra efectivos en pocas municipalidades o si la distribución es más extendida.

10.4. Lollipop de ranking


Pregunta: ¿qué municipalidades concentran el mayor número de intervenciones registradas por serenazgo?

```
renamu_seguridad |>
  arrange(desc(total_intervenciones)) |>
  slice_head(n = 15) |>
  mutate(municipalidad = str_c(distrito, " (", departamento, ")")) |>
  ggplot(aes(
    x = total_intervenciones,
    y = reorder(municipalidad, total_intervenciones)
  )) +
  geom_segment(
    aes(x = 0, xend = total_intervenciones, yend = municipalidad),
```

```

    color = "#b8b8b8"
  ) +
  geom_point(size = 3, color = "#b56576") +
  scale_x_continuous(labels = comma_format()) +
  labs(
    title = "Ranking de municipalidades por intervenciones",
    subtitle = "Gráfico lollipop",
    x = "Intervenciones registradas",
    y = NULL
  ) +
  tema_sesion()

```



El lollipop es una alternativa más liviana al barplot cuando queremos mostrar un ranking. Funciona bien si el interés está en el orden y la distancia entre casos.

10.5. Barras agrupadas y apiladas


Pregunta: ¿las municipalidades provinciales y distritales tienen el mismo perfil de recursos para serenazgo?

```

recursos_tipo <- renamu_seguridad |>
  group_by(tipo_municipalidad) |>
  summarise(
    auto_o_camioneta = mean(p70_1 == 1, na.rm = TRUE),
    radio = mean(p70_6 == 1, na.rm = TRUE),
    camaras = mean(p70_7 == 1, na.rm = TRUE),
    central = mean(p70_10 == 1, na.rm = TRUE),
    chaleco = mean(p70_13 == 1, na.rm = TRUE),
    .groups = "drop"
  ) |>
  pivot_longer(
    cols = -tipo_municipalidad,
    names_to = "recurso",
    values_to = "porcentaje"
  ) |>
  mutate(recurso = str_replace_all(recurso, "_", " "))

recursos_tipo |>
  ggplot(aes(x = recurso, y = porcentaje, fill = tipo_municipalidad)) +
  geom_col(position = position_dodge(width = 0.75), width = 0.7) +
  coord_flip() +
  scale_y_continuous(labels = percent_format()) +
  scale_fill_paletteer_d("MetBrewer::Archambault") +
  labs(
    title = "Recursos municipales por tipo de municipalidad",
    subtitle = "Barras agrupadas",
    x = NULL,
    y = "Porcentaje con recurso",
    fill = NULL
  ) +
  tema_sesion()

```




Las barras agrupadas comparan porcentajes entre dos grupos. Aquí permiten ver diferencias entre municipalidades provinciales y distritales en capacidades de serenazgo.

Pregunta: ¿cómo cambia la composición relativa de recursos entre tipos de municipalidad?

```
recursos_tipo |>
  group_by(tipo_municipalidad) |>
  mutate(participacion = porcentaje / sum(porcentaje, na.rm = TRUE)) |>
  ungroup() |>
  ggplot(aes(x = tipo_municipalidad, y = participacion, fill = recurso)) +
  geom_col(width = 0.65) +
  scale_y_continuous(labels = percent_format()) +
  scale_fill_paletteer_d("ggsci::category20_d3") +
  labs(
    title = "Composición relativa de recursos observados",
    subtitle = "Barras apiladas normalizadas",
    x = NULL,
    y = "Participación dentro del conjunto de recursos",
    fill = "Recurso"
```



```
) +  
tema_sesion()
```



Las barras apiladas normalizadas muestran composición, no volumen absoluto. Sirven para comparar perfiles, pero no reemplazan el gráfico anterior.

10.6. Bubble plot interactivo

Pregunta: ¿los departamentos con más efectivos y cámaras son también los que registran más intervenciones?

```
indicadores_burbujas <- renamu_seguridad |>  
  group_by(departamento) |>  
  summarise(  
    municipalidades = n(),  
    efectivos = sum(p69_2_t, na.rm = TRUE),  
    camaras = sum(p70a_7_1, na.rm = TRUE),  
    intervenciones = sum(total_intervenciones, na.rm = TRUE),
```

```

    porcentaje_serenazgo = mean(p69_2 == 1, na.rm = TRUE),
    .groups = "drop"
  )

plotly::plot_ly(
  data = indicadores_burbujas,
  x = ~efectivos,
  y = ~intervenciones,
  type = "scatter",
  mode = "markers",
  size = ~camaras,
  color = ~porcentaje_serenazgo,
  colors = c("#0d0887", "#7e03a8", "#cc4778", "#f89540", "#f0f921"),
  sizes = c(8, 38),
  marker = list(opacity = 0.75, line = list(width = 1, color = "white")),
  text = ~ str_c(
    departamento,
    "<br>Efectivos: ",
    comma(efectivos),
    "<br>Intervenciones: ",
    comma(intervenciones),
    "<br>Cámaras: ",
    comma(camaras),
    "<br>% con serenazgo: ",
    percent(porcentaje_serenazgo, accuracy = 0.1)
  ),
  hoverinfo = "text"
) |>
plotly::layout(
  title = "Capacidad municipal e intervenciones por departamento",
  xaxis = list(title = "Efectivos de serenazgo", type = "log"),
  yaxis = list(title = "Intervenciones registradas", type = "log"),
  legend = list(orientation = "h", x = 0, y = -0.2)
)

```


El bubble plot permite ver tres dimensiones a la vez: efectivos, intervenciones y cámaras. Con plotly, el gráfico se vuelve interactivo y permite consultar cada departamento. Usamos plot_ly() directamente porque suele ser más estable que convertir un gráfico complejo desde ggplot2.

Sin embargo, este bloque solo se activará en el renderizado HTML por motivos de compatibilidad.

10.7. Heatmap de intervenciones

Pregunta: ¿qué tipos de intervención pesan más dentro de cada departamento?

```
intervenciones_larga |>
  group_by(departamento, tipo_intervencion) |>
  summarise(
    intervenciones = sum(intervenciones, na.rm = TRUE),
    .groups = "drop"
  ) |>
  group_by(departamento) |>
  mutate(participacion = intervenciones / sum(intervenciones, na.rm = TRUE)) |>
  ungroup() |>
  semi_join(
    intervenciones_departamento |> slice_max(total_intervenciones, n = 12),
    by = "departamento"
  ) |>
  ggplot(aes(
    x = tipo_intervencion,
    y = reorder(departamento, participacion),
    fill = participacion
  )) +
  geom_tile(color = "white", linewidth = 0.2) +
  scale_fill_paletteer_c("viridis::rocket", labels = percent_format()) +
  labs(
    title = "Composición de intervenciones por departamento",
    subtitle = "Heatmap de porcentajes dentro de cada departamento",
    x = NULL,
    y = NULL,
    fill = "Participación"
  ) +
  tema_sesion() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



El heatmap ayuda cuando tenemos dos dimensiones categóricas. Aquí permite ver qué tipos de intervención pesan más dentro de cada departamento.

10.8. Correlograma de indicadores

Pregunta: ¿qué indicadores municipales tienden a moverse juntos?


```
indicadores_correlacion <- renamu_seguridad |>
  transmute(
    efectivos = p69_2_t,
    autos_camionetas = p70a_1_1,
    radios = p70a_6_1,
    camaras = p70a_7_1,
    camaras_operativas = p70a_7_2,
    centrales = p70a_10_1,
    chalecos = p70a_13_1,
    intervenciones = total_intervenciones
  )
```

```

correlaciones <- cor(
  indicadores_correlacion,
  use = "pairwise.complete.obs"
) |>
as.data.frame() |>
rownames_to_column("variable_1") |>
pivot_longer(
  cols = -variable_1,
  names_to = "variable_2",
  values_to = "correlacion"
)

correlaciones |>
mutate(color_texto = if_else(abs(correlacion) > 0.55, "white", "black")) |>
ggplot(aes(x = variable_1, y = variable_2, fill = correlacion)) +
geom_tile(color = "white", linewidth = 0.25) +
geom_text(
  aes(label = number(correlacion, accuracy = 0.01), color = color_texto),
  size = 2.8
) +
scale_fill_gradient2(
  low = "#b56576",
  mid = "white",
  high = "#2f6f73",
  midpoint = 0,
  limits = c(-1, 1)
) +
scale_color_identity() +
labs(
  title = "Correlograma de indicadores municipales",
  x = NULL,
  y = NULL,
  fill = "Correlación"
) +
tema_sesion() +
theme(axis.text.x = element_text(angle = 45, hjust = 1))

```



El correlograma resume relaciones lineales entre variables numéricas. En esta sesión lo usamos como exploración, no como evidencia causal.

10.9. Dispersión y densidad 2D

Pregunta: ¿hay relación entre tener más cámaras operativas y registrar más intervenciones?

```
datos_camaras_intervenciones <- renamu_seguridad |>
  filter(
    !is.na(p70a_7_2),
    p70a_7_2 > 0,
    total_intervenciones > 0
  )

grafico_dispersion <- datos_camaras_intervenciones |>
  ggplot(aes(x = p70a_7_2, y = total_intervenciones)) +
  geom_point(alpha = 0.45, color = "#2f6f73") +
  geom_smooth(method = "lm", se = FALSE, color = "#b56576", linewidth = 0.8) +
  scale_x_log10(labels = comma_format()) +
```


```

scale_y_log10(labels = comma_format()) +
labs(
  title = "Scatter plot",
  subtitle = "Cada punto es una municipalidad",
  x = "Cámaras operativas",
  y = "Intervenciones registradas"
) +
tema_sesion()

grafico_densidad_2d <- datos_cameras_intervenciones |>
ggplot(aes(x = p70a_7_2, y = total_intervenciones)) +
stat_density_2d(
  aes(fill = after_stat(level)),
  geom = "polygon",
  alpha = 0.75
) +
geom_point(alpha = 0.15, size = 0.8, color = "white") +
scale_x_log10(labels = comma_format()) +
scale_y_log10(labels = comma_format()) +
scale_fill_paletteer_c("viridis::mako", guide = "none") +
labs(
  title = "Densidad 2D",
  subtitle = "Zonas donde se concentran más municipalidades",
  x = "Cámaras operativas",
  y = "Intervenciones registradas"
) +
tema_sesion()

grafico_dispersion + grafico_densidad_2d

```



El scatter muestra casos individuales; la densidad 2D muestra dónde se agrupan. Cuando hay muchos puntos y una cola larga, mirar ambas versiones evita sobreinterpretar casos extremos.

10.10. Treemap de intervenciones

Pregunta: ¿qué tipos de intervención ocupan la mayor parte del total registrado?

```
intervenciones_tipo |>
  mutate(
    etiqueta = str_replace_all(tipo_intervencion, "_", " "),
    etiqueta = str_to_sentence(etiqueta)
  ) |>
  ggplot(aes(
    area = intervenciones,
    fill = tipo_intervencion,
    label = etiqueta
  )) +
  treemapify::geom_treemap(color = "white", linewidth = 0.8) +
  treemapify::geom_treemap_text(
```



```

    color = "white",
    place = "center",
    grow = TRUE,
    reflow = TRUE,
    min.size = 6
  ) +
  scale_fill_paletteer_d("ggsci::category20_d3", guide = "none") +
  labs(
    title = "Treemap de intervenciones registradas",
    subtitle = "El tamaño de cada rectángulo representa el volumen de intervenciones"
  ) +
  tema_sesion() +
  theme(
    axis.text = element_blank(),
    axis.title = element_blank(),
    panel.grid = element_blank()
  )

```




El treemap funciona para mostrar partes de un total cuando hay varias categorías. Es menos preciso que una barra ordenada, pero ayuda a comunicar concentración.

10.11. Heatmap de recursos categóricos

Pregunta: ¿qué tan frecuente es que una municipalidad tenga central de videovigilancia y chalecos antibalas al mismo tiempo?

```
renamu_seguridad |>
  mutate(
    central = etiquetar_si_no(p70_10),
    chaleco = etiquetar_si_no(p70_13)
  ) |>
  filter(central %in% c("Sí", "No"), chaleco %in% c("Sí", "No")) |>
  count(central, chaleco, name = "municipalidades") |>
  group_by(central) |>
  mutate(porcentaje_fila = municipalidades / sum(municipalidades)) |>
  ungroup() |>
  mutate(color_texto = if_else(municipalidades < 500, "white", "black")) |>
  ggplot(aes(x = chaleco, y = central, fill = municipalidades)) +
  geom_tile(color = "white", linewidth = 0.8) +
  geom_text(
    aes(
      label = str_c(
        comma(municipalidades),
        "\n",
        percent(porcentaje_fila, accuracy = 0.1)
      ),
      color = color_texto
    ),
    size = 3.6
  ) +
  scale_fill_paletteer_c("viridis::rocket", labels = comma_format()) +
  scale_color_identity() +
  labs(
    title = "Cruce entre central de videovigilancia y chalecos",
    subtitle = "Conteos y porcentajes dentro de cada fila",
    x = "Tiene chalecos antibalas",
    y = "Tiene central de videovigilancia",
    fill = "Municipalidades"
  ) +
  tema_sesion()
```



Este heatmap trabaja con dos variables categóricas. Es una forma compacta de leer combinaciones, no solo porcentajes separados.

10.12. Base complementaria de celulares


Pregunta: ¿en qué departamentos se concentran los registros de robo de celular de la base complementaria?

```
preparar_base_celular()

celular_departamento <- base_celular |>
  count(dpto_hecho_new, sort = TRUE, name = "denuncias") |>
  filter(!is.na(dpto_hecho_new)) |>
  slice_max(denuncias, n = 15)

celular_departamento |>
  ggplot(aes(x = denuncias, y = reorder(dpto_hecho_new, denuncias))) +
  geom_col(fill = "#577590") +
  scale_x_continuous(labels = comma_format()) +
```

```
labs(
  title = "Registros de robo de celular por departamento",
  subtitle = "Base complementaria SIDPOL",
  x = "Registros",
  y = NULL
) +
tema_sesion()
```



Esta visualización usa una base complementaria para practicar ranking con registros policiales. La lectura es descriptiva: muestra concentración territorial de los registros disponibles.


Pregunta: ¿la edad de las personas registradas cambia según sexo?

```
base_celular |>
  filter(
    sexo %in% c("Mujer", "Hombre"),
    !is.na(edad),
    edad >= 10,
    edad <= 90
  )
```

```

) |>
ggplot(aes(x = edad, fill = sexo, color = sexo)) +
  geom_density(alpha = 0.35, linewidth = 0.8) +
  scale_fill_manual(values = c("Mujer" = "#b56576", "Hombre" = "#577590")) +
  scale_color_manual(values = c("Mujer" = "#b56576", "Hombre" = "#577590")) +
  labs(
    title = "Distribución de edad en registros de robo de celular",
    subtitle = "Densidad por sexo",
    x = "Edad",
    y = "Densidad",
    fill = NULL,
    color = NULL
  ) +
  tema_sesion()

```



La densidad por sexo permite comparar formas de distribución, no solo promedios. Aquí interesa ver si las edades se concentran en rangos similares o distintos.

10.13. Serie temporal con archivo complementario


Pregunta: ¿cómo evolucionan algunos indicadores operativos a lo largo del tiempo?

```
preparar_data_prepara()

variables_tiempo <- c(
  "OPERATIVOS",
  "ARMAS DE FUEGO",
  "DETENIDOS DIVERSOS DELITOS (PERUANOS)",
  "MARIHUANA (KILOS)"
)

serie_tiempo <- data_prepara |>
  filter(variable %in% variables_tiempo) |>
  group_by(fecha, variable) |>
  summarise(valor = sum(valor, na.rm = TRUE), .groups = "drop") |>
  mutate(
    variable_grafico = recode(
      variable,
      "DETENIDOS DIVERSOS DELITOS (PERUANOS)" = "DETENIDOS\nPERUANOS"
    )
  )

serie_tiempo |>
  ggplot(aes(x = fecha, y = valor, color = variable)) +
  geom_line(linewidth = 0.9, show.legend = FALSE) +
  geom_point(size = 1.4, show.legend = FALSE) +
  facet_wrap(~variable_grafico, scales = "free_y", ncol = 2) +
  scale_x_date(date_breaks = "6 months", date_labels = "%Y-%m") +
  scale_y_continuous(labels = comma_format()) +
  scale_color_paletteer_d("MetBrewer::Johnson") +
  labs(
    title = "Evolución mensual de indicadores complementarios",
    subtitle = "Archivo data_prepara.xlsx",
    x = NULL,
    y = "Valor registrado"
  ) +
  tema_sesion() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```




Los gráficos de línea son adecuados cuando hay una dimensión temporal. Aquí el objetivo es mostrar evolución, estacionalidad y posibles picos.

Pregunta: ¿las series tienen patrones temporales parecidos aunque estén en escalas distintas?

```
serie_tiempo |>
  group_by(variable) |>
  mutate(indice = valor / max(valor, na.rm = TRUE)) |>
  ungroup() |>
  ggplot(aes(x = fecha, y = indice, fill = variable)) +
  geom_area(alpha = 0.65, position = "identity", show.legend = FALSE) +
  facet_wrap(~variable_grafico, ncol = 2) +
  scale_x_date(date_breaks = "6 months", date_labels = "%Y-%m") +
  scale_y_continuous(labels = percent_format()) +
  scale_fill_paletteer_d("MetBrewer::Johnson") +
  labs(
    title = "Área normalizada por indicador",
    subtitle = "Cada serie se expresa como porcentaje de su propio máximo",
    x = NULL,
    y = "Índice"
  )
```

```
) +
tema_sesion() +
theme(
  axis.text.x = element_text(angle = 45, hjust = 1),
  strip.text = element_text(size = 9.5)
)
```



El área normalizada no compara magnitudes absolutas, sino patrones de evolución. Es útil cuando las variables tienen escalas muy distintas.

11. Diccionario mínimo de trabajo

```
diccionario_sesion_3 <- tibble(
  variable = c(
    "ubigeo",
    "departamento",
```



```

    "provincia",
    "distrito",
    "tipo_municipalidad",
    "p69_2",
    "p69_2_t",
    "p70_7",
    "p70a_7_1",
    "p70a_7_2",
    "p70a_7_4",
    "p70_10",
    "total_intervenciones"
  ),
  descripcion = c(
    "Código territorial de seis dígitos.",
    "Departamento de la municipalidad.",
    "Provincia de la municipalidad.",
    "Distrito de la municipalidad.",
    "Tipo de municipalidad: provincial o distrital.",
    "Indica si la municipalidad brindó serenazgo al 31 de marzo de 2025.",
    "Total de efectivos de serenazgo al 31 de marzo de 2025.",
    "Indica si la municipalidad dispone de cámaras de videovigilancia.",
    "Total de cámaras de videovigilancia.",
    "Cámaras de videovigilancia operativas.",
    "Cámaras operativas integradas a la PNP.",
    "Indica si el serenazgo dispone de central de control de videovigilancia.",
    "Suma de intervenciones registradas por serenazgo en las categorías P71."
  ),
  fuente = "RENAMU 2025"
)

diccionario_sesion_3

```

A tibble: 13 x 3

	variable	descripcion	fuentes
	<chr>	<chr>	<chr>
1	ubigeo	Código territorial de seis dígitos.	RENAM~
2	departamento	Departamento de la municipalidad.	RENAM~
3	provincia	Provincia de la municipalidad.	RENAM~
4	distrito	Distrito de la municipalidad.	RENAM~
5	tipo_municipalidad	Tipo de municipalidad: provincial o distrital.	RENAM~
6	p69_2	Indica si la municipalidad brindó serenazgo al 3~	RENAM~
7	p69_2_t	Total de efectivos de serenazgo al 31 de marzo d~	RENAM~

8	p70_7	Indica si la municipalidad dispone de cámaras de	RENAM~
9	p70a_7_1	Total de cámaras de videovigilancia.	RENAM~
10	p70a_7_2	Cámaras de videovigilancia operativas.	RENAM~
11	p70a_7_4	Cámaras operativas integradas a la PNP.	RENAM~
12	p70_10	Indica si el serenazgo dispone de central de con~	RENAM~
13	total_intervenciones	Suma de intervenciones registradas por serenazgo~	RENAM~

El diccionario mínimo traduce códigos de cuestionario a variables interpretables. Esta práctica evita que el análisis dependa de memoria o de nombres crípticos.

12. Exportar resultados

```
base_renamu_seguridad <- renamu_seguridad |>
select(
  ano,
  ubigeo,
  departamento,
  provincia,
  distrito,
  tipo_municipalidad,
  serenazgo_2024,
  serenazgo_2025,
  p69_2_t,
  p69_2_m,
  p69_2_h,
  tiene_auto_camioneta,
  p70a_1_1,
  p70a_1_2,
  p70a_1_3,
  tiene_radio,
  p70a_6_1,
  p70a_6_2,
  p70a_6_3,
  tiene_camaras,
  p70a_7_1,
  p70a_7_2,
  p70a_7_3,
  p70a_7_4,
  tiene_central_videovigilancia,
  p70a_10_1,
```

```

    p70a_10_2,
    p70a_10_3,
    tiene_chaleco_antibalas,
    p70a_13_1,
    total_intervenciones
  )

indicadores_departamento <- renamu_seguridad |>
  group_by(departamento) |>
  summarise(
    municipalidades = n(),
    con_serenazgo = sum(p69_2 == 1, na.rm = TRUE),
    porcentaje_serenazgo = con_serenazgo / municipalidades,
    efectivos_serenazgo = sum(p69_2_t, na.rm = TRUE),
    con_camaras = sum(p70_7 == 1, na.rm = TRUE),
    total_camaras = sum(p70a_7_1, na.rm = TRUE),
    camaras_operativas = sum(p70a_7_2, na.rm = TRUE),
    intervenciones_serenazgo = sum(total_intervenciones, na.rm = TRUE),
    .groups = "drop"
  )

write_csv(
  base_renamu_seguridad,
  file.path(ruta_resultados, "base_sesion3.csv")
)

write_csv(
  indicadores_departamento,
  file.path(ruta_resultados, "indicadores_sesion3.csv")
)

write_csv(
  diccionario_sesion_3,
  file.path(ruta_resultados, "diccionario_sesion3.csv")
)

```

La exportación deja una base municipal simplificada, un resumen departamental y un diccionario mínimo. Esos productos pueden reutilizarse para tareas o para sesiones posteriores.

13. Ejercicios para seguir practicando

1. Identificar los cinco departamentos con mayor porcentaje de municipalidades con serenazgo.
2. Calcular el porcentaje de cámaras operativas por departamento.
3. Encontrar municipalidades que declaran tener cámaras, pero registran cero cámaras operativas.
4. Comparar la mediana de intervenciones entre municipalidades provinciales y distritales.
5. Crear un gráfico de barras con los tres tipos de intervención más frecuentes.
6. Revisar si las municipalidades con central de videovigilancia tienen más cámaras operativas.
7. Exportar una base solo con municipalidades de Lima Metropolitana o Callao.

Estos ejercicios pueden apoyarse en el Posit Assistant de RStudio para revisar errores, pedir explicaciones de código y explorar alternativas de limpieza o visualización.