

Indicadores de victimización y percepción de inseguridad

ENAPRES, sintaxis SPSS, estimación de indicadores y análisis comparado

Noam López Villanes

16 de mayo de 2026

Tabla de contenidos

1	Objetivo de la sesión	1
2	Preparación	2
3	Importar resultados calculados	2
4	Tendencias nacionales	6
5	Diferencias territoriales	9
6	Relacionar indicadores	13
7	Cómo se calculan los indicadores	17
8	Estimación e inferencia	23
9	Ejercicios para seguir practicando	31

1. Objetivo de la sesión

En esta sesión trabajaremos con indicadores de victimización, percepción de inseguridad y confianza en la Policía Nacional del Perú a partir de ENAPRES. La sesión tiene dos propósitos: reconstruir la serie 2010-2025 desde microdatos y usar esos indicadores para hacer ejercicios de estadística inferencial.

1. Importar bases con codificación correcta.

2. Reconocer indicadores, años y ámbitos de análisis.
3. Comparar tendencias nacionales y diferencias departamentales.
4. Replicar indicadores desde microdatos de seguridad ciudadana.
5. Revisar filtros, factores de expansión y cambios de cuestionario entre años.
6. Relacionar victimización, percepción y confianza en la PNP.
7. Estimar porcentajes ponderados, intervalos de confianza y asociaciones bivariadas.

2. Preparación

Si ejecutas este documento por partes, corre primero los chunks de **Instalar paquetes**, **Activar paquetes** y **Ubicar archivos**. Los tres están ocultos en el redimensionado final, pero esos bloques crean los paquetes, funciones y rutas que usan los demás chunks.

3. Importar resultados calculados

¿Qué resultados generó nuestro script a partir de los microdatos?

```
archivo_micro_nacional <- file.path(
  ruta_resultados,
  "enapres_indicadores_nacionales.csv"
)
archivo_micro_region <- file.path(
  ruta_resultados,
  "enapres_indicadores_region.csv"
)
archivo_micro_individual <- file.path(
  ruta_resultados,
  "enapres_microdatos_indicadores.csv"
)

if (
  !file.exists(archivo_micro_nacional) ||
  !file.exists(archivo_micro_region) ||
  !file.exists(archivo_micro_individual)
) {
  source(file.path(ruta_scripts, "procesar_enapres_mod600.R"))
}

micro_nacional <- read_csv(archivo_micro_nacional, show_col_types = FALSE)
micro_region <- read_csv(archivo_micro_region, show_col_types = FALSE)
```

```

micro_individual <- read_csv(
  archivo_micro_individual,
  show_col_types = FALSE
) |>
mutate(
  sexo = factor(sexo, levels = c("Hombre", "Mujer")),
  grupo_edad = factor(
    grupo_edad,
    levels = c("15 a 24", "25 a 39", "40 a 59", "60 a más")
  )
)

nombres_indicadores <- c(
  victimizacion = "Victimización",
  percepcion_12m = "Percepción próximos 12 meses",
  percepcion_noche = "Percepción al caminar de noche",
  percepcion_dia = "Percepción al caminar de día",
  confianza_pnp = "Confianza en la PNP",
  robo_intento_dinero_cartera_celular = "Robo o intento de robo",
  estafa = "Estafa"
)

indicadores_nacionales_largo <- micro_nacional |>
pivot_longer(
  cols = any_of(names(nombres_indicadores)),
  names_to = "indicador",
  values_to = "valor"
) |>
mutate(
  indicador = recode(indicador, !!!nombres_indicadores)
)

indicadores_region_largo <- micro_region |>
pivot_longer(
  cols = any_of(names(nombres_indicadores)),
  names_to = "indicador",
  values_to = "valor"
) |>
mutate(
  indicador = recode(indicador, !!!nombres_indicadores)
)

```

```
glimpse(micro_nacional)
```

```
Rows: 16
```

```
Columns: 10
```

```
$ anio <dbl> 2010, 2011, 2012, 2013, 2014, 2015~
$ personas_victimizacion <dbl> 89142, 85985, 84752, 84218, 71776,~
$ personas_percepcion <dbl> 89142, 85985, 84752, 84218, 71776,~
$ victimizacion <dbl> 14.24518, 20.84287, 18.40321, 35.8~
$ percepcion_12m <dbl> 79.23058, 86.16190, 84.87617, 87.5~
$ percepcion_noche <dbl> NA, NA, NA, 58.13288, 58.44583, 58~
$ percepcion_dia <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA~
$ confianza_pnp <dbl> 37.88785, 27.58795, 24.32636, 20.4~
$ robo_intento_dinero_cartera_celular <dbl> 21.35755, 23.41902, 21.26860, 21.9~
$ estafa <dbl> 4.783240, 1.291354, 11.050427, 11.~
```

```
glimpse(micro_individual)
```

```
Rows: 3,524,357
```

```
Columns: 24
```

```
$ archivo <chr> "ENAPRES 2010.sav", "ENAPRES 2010.~
$ version_cuestionario <chr> "cuestionario_2019_2023_cap600", "~
$ anio <dbl> 2010, 2010, 2010, 2010, 2010, 2010, 2010~
$ mes <chr> "05", "05", "05", "05", "05", "05"~
$ ccdd <chr> "24", "24", "24", "24", "24", "24"~
$ ccpp <chr> "01", "01", "01", "01", "01", "01"~
$ departamento <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA~
$ region_final <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA~
$ conglomerado <chr> "00036", "00036", "00036", "00036"~
$ vivienda <chr> "001", "001", "001", "002", "002",~
$ hogar <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1~
$ estrato <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA~
$ sexo <fct> Hombre, Mujer, Mujer, Hombre, Muje~
$ edad <dbl> 38, 30, 15, 49, 45, 14, 45, 41, 20~
$ grupo_edad <fct> 25 a 39, 25 a 39, 15 a 24, 40 a 59~
$ peso_victimizacion <dbl> 53.38186, 53.38186, 53.38186, 53.3~
$ peso_percepcion <dbl> 53.38186, 53.38186, 53.38186, 53.3~
$ victimizacion <dbl> 0, 0, 0, 0, 0, NA, 0, 0, 0, 0, 1, ~
$ percepcion_12m <dbl> 0, 0, 0, 0, 0, NA, 1, 0, 0, 0, 0, ~
$ percepcion_noche <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA~
$ percepcion_dia <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA~
$ confianza_pnp <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA~
```

```
$ robo_intento_dinero_cartera_celular <dbl> 0, 0, 0, 0, 0, NA, 0, 0, 0, 0, 1, ~
$ estafa                                <dbl> 0, 0, 0, 0, 0, NA, 0, 0, 0, 0, 0, ~
```

El archivo individual conserva una fila por persona y agrega los indicadores calculados. Los archivos nacional y regional son resúmenes ponderados, es decir, usan el factor de expansión para estimar porcentajes poblacionales.

¿Hay valores perdidos o años incompletos que debamos tener presentes antes de graficar?

```
micro_nacional |>
  summarise(
    filas = n(),
    columnas = ncol(micro_nacional),
    anio_minimo = min(anio, na.rm = TRUE),
    anio_maximo = max(anio, na.rm = TRUE)
  )
```

```
# A tibble: 1 x 4
  filas columnas anio_minimo anio_maximo
  <int>   <int>   <dbl>   <dbl>
1    16      10    2010    2025
```

```
indicadores_nacionales_largo |>
  group_by(indicador) |>
  summarise(
    primer_anio = min(anio[!is.na(valor)], na.rm = TRUE),
    ultimo_anio = max(anio[!is.na(valor)], na.rm = TRUE),
    anios_con_dato = sum(!is.na(valor)),
    .groups = "drop"
  )
```

```
# A tibble: 7 x 4
  indicador primer_anio ultimo_anio anios_con_dato
  <chr>         <dbl>     <dbl>     <int>
1 Confianza en la PNP      2010      2025        16
2 Estafa                  2010      2025        16
3 Percepción al caminar de día      2022      2024         3
4 Percepción al caminar de noche      2013      2025        13
5 Percepción próximos 12 meses      2010      2025        16
6 Robo o intento de robo      2010      2025        16
7 Victimización            2010      2025        16
```

La cobertura temporal no es idéntica para todos los indicadores. Por eso conviene mirar primero qué años están disponibles antes de comparar tendencias.

4. Tendencias nacionales

¿Cómo evolucionan los principales indicadores nacionales de seguridad que calculamos desde microdatos?

```
indicadores_nacionales_grafico <- indicadores_nacionales_largo |>
  filter(!is.na(valor)) |>
  filter(
    indicador %in%
      c(
        "Victimización",
        "Percepción al caminar de noche",
        "Confianza en la PNP",
        "Robo o intento de robo",
        "Estafa"
      )
  )


etiquetas_nacionales <- indicadores_nacionales_grafico |>
  group_by(indicador) |>
  filter(anio == max(anio, na.rm = TRUE)) |>
  ungroup()

indicadores_nacionales_grafico |>
  ggplot(aes(
    x = anio,
    y = valor / 100,
    color = indicador
  )) +
  geom_line(linewidth = 1.05) +
  geom_text(
    data = etiquetas_nacionales,
    aes(label = percent(valor / 100, accuracy = 0.1)),
    hjust = -0.12,
    size = 2.7,
    show.legend = FALSE
  ) +
  scale_y_continuous(
```

```

    labels = percent_format(),
    expand = expansion(mult = c(0.04, 0.08))
  ) +
  scale_x_continuous(
    breaks = seq(min(micro_nacional$anio), max(micro_nacional$anio), by = 2),
    expand = expansion(mult = c(0.02, 0.08))
  ) +
  scale_color_paletteer_d("ggthemes::Tableau_10") +
  labs(
    title = "Indicadores ENAPRES calculados desde microdatos, 2010-2025",
    x = NULL,
    y = "Porcentaje",
    color = NULL,
    caption = "Nota: las estimaciones usan el factor de expansión; 2025 pertenece a una etapa"
  ) +
  tema_sesion() +
  theme(
    plot.caption = element_text(hjust = 0, color = "grey35", size = 9),
    plot.title = element_text(size = 14),
    legend.box = "vertical"
  )
)

```



La comparación temporal permite ver que victimización y percepción no necesariamente se mueven igual. Como las estimaciones salen de microdatos, el punto central de la clase es entender qué estamos estimando y cómo el factor de expansión convierte respuestas muestrales en porcentajes poblacionales.


¿Qué indicador cambió más entre el primer y el último año disponible?

```
cambios_nacionales <- indicadores_nacionales_grafico |>
  filter(!is.na(valor)) |>
  arrange(indicador, anio) |>
  group_by(indicador) |>
  summarise(
    primer_anio = first(anio),
    ultimo_anio = last(anio),
    primer_valor = first(valor),
    ultimo_valor = last(valor),
    cambio_puntos = ultimo_valor - primer_valor,
    comparacion = str_c(primer_anio, "-", ultimo_anio),
    etiqueta = str_c(
      number(cambio_puntos, accuracy = 0.1),
      " pp (",
      comparacion,
      ")"
    ),
    .groups = "drop"
  )

cambios_nacionales |>
  ggplot(aes(
    x = reorder(indicador, cambio_puntos),
    y = cambio_puntos
  )) +
  geom_hline(yintercept = 0, color = "grey70") +
  geom_col(aes(fill = cambio_puntos > 0), width = 0.7, show.legend = FALSE) +
  geom_text(
    aes(
      y = if_else(cambio_puntos < 0, -0.12, 0.12),
      label = etiqueta,
      hjust = if_else(cambio_puntos < 0, 1.03, -0.03)
    ),
    size = 3.5,
    color = "grey20"
  ) +
```



```
coord_flip() +
scale_fill_manual(values = c("#3a86ff", "#ef476f")) +
scale_y_continuous(expand = expansion(mult = c(0.08, 0.12))) +
labs(
  title = "Cambio entre el primer y el último año disponible",
  subtitle = "Diferencia en puntos porcentuales; entre paréntesis se muestran los años comp",
  x = NULL,
  y = "Puntos porcentuales"
) +
tema_sesion() +
theme(plot.title = element_text(size = 15))
```



Esta forma de resumir el cambio ayuda a no quedarnos solo con la última foto. Un indicador puede estar alto, pero haber caído; otro puede estar bajo, pero creciendo.

5. Diferencias territoriales

¿Qué departamentos muestran mayores niveles de victimización en el último año disponible?

```

ultimo_anio <- max(micro_region$anio, na.rm = TRUE)


ranking_departamental <- indicadores_region_largo |>
  filter(
    anio == ultimo_anio,
    indicador == "Victimización"
  ) |>
  arrange(desc(valor))

ranking_departamental |>
  slice_max(valor, n = 15) |>
  ggplot(aes(x = valor / 100, y = reorder(region_final, valor))) +
  geom_segment(
    aes(x = 0, xend = valor / 100, yend = region_final),
    color = "grey78"
  ) +
  geom_point(size = 3.2, color = "#ef476f") +
  geom_text(
    aes(label = percent(valor / 100, accuracy = 0.1)),
    hjust = -0.15,
    size = 3.2
  ) +
  scale_x_continuous(
    labels = percent_format(),
    limits = c(0, max(ranking_departamental$valor) / 100 * 1.18)
  ) +
  labs(
    title = glue("Departamentos con mayor victimización en {ultimo_anio}"),
    subtitle = "Indicador calculado por ENAPRES",
    x = "Victimización",
    y = NULL
  ) +
  tema_sesion()

```

Departamentos con mayor victimización en 2025

Indicador calculado por ENAPRES



El ranking sirve para ubicar casos extremos, pero no debe confundirse con una explicación. Para explicar diferencias territoriales se necesita relacionar estos indicadores con otras características sociales, institucionales o urbanas.

¿Cómo se distribuye la victimización departamental a lo largo del tiempo?


```
victimizacion_departamental <- indicadores_region_largo |>
  filter(
    indicador == "Victimización"
  )

victimizacion_departamental |>
  group_by(region_final) |>
  mutate(promedio_departamento = mean(valor, na.rm = TRUE)) |>
  ungroup() |>
  ggplot(aes(
    x = anio,
    y = reorder(region_final, promedio_departamento),
    fill = valor / 100
  )) +
  geom_tile(color = "white", linewidth = 0.2) +
```

```

scale_fill_paletteer_c("viridis::magma", labels = percent_format()) +
scale_x_continuous(breaks = sort(unique(victimizacion_departamental$anio))) +
labs(
  title = "Victimización por departamento y año",
  subtitle = "Mapa de calor de porcentajes",
  x = NULL,
  y = NULL,
  fill = "Victimización"
) +
tema_sesion() +
theme(axis.text.y = element_text(size = 7.5))

```



El mapa de calor permite detectar persistencias y cambios simultáneamente. Es útil para preguntar si un departamento aparece sistemáticamente alto o si tuvo un aumento puntual.


6. Relacionar indicadores

¿Los lugares con más victimización también tienen mayor percepción al caminar de noche?

```
indicadores_ultimo_anio <- indicadores_region_largo |>
  filter(
    anio == ultimo_anio,
    indicador %in%
      c(
        "Victimización",
        "Percepción al caminar de noche",
        "Confianza en la PNP"
      )
  ) |>
  select(region_final, indicador, valor) |>
  pivot_wider(names_from = indicador, values_from = valor) |>
  clean_names()

grafico_victimizacion_percepcion <- indicadores_ultimo_anio |>
  ggplot(aes(
    x = victimizacion / 100,
    y = percepcion_al_caminar_de_noche / 100,
    text = glue(
      "{region_final}<br>",
      "Victimización: {percent(victimizacion / 100, accuracy = 0.1)}<br>",
      "Percepción al caminar de noche: {percent(percepcion_al_caminar_de_noche / 100, accuracy = 0.1)}<br>",
      "Confianza en la PNP: {percent(confianza_en_la_pnp / 100, accuracy = 0.1)}"
    )
  )) +
  geom_point(aes(color = confianza_en_la_pnp / 100), size = 3.2, alpha = 0.85) +
  geom_smooth(method = "lm", se = FALSE, color = "grey35", linewidth = 0.8) +
  scale_x_continuous(labels = percent_format()) +
  scale_y_continuous(labels = percent_format()) +
  scale_color_paletteer_c("viridis::plasma", labels = percent_format()) +
  labs(
    title = glue(
      "Victimización y percepción al caminar de noche en {ultimo_anio}"
    ),
    subtitle = "Cada punto representa un departamento",
    x = "Victimización",
    y = "Percepción al caminar de noche",
    color = "Confianza en la PNP"
  )
```

```
) +  
  tema_sesion()  
  
ggplotly(grafico_victimizacion_percepcion, tooltip = "text")
```



La nube de puntos permite discutir si la percepción de inseguridad acompaña a la victimización

o si hay departamentos donde ambas variables se separan. Esa separación puede convertirse en una pregunta de investigación.

¿Dónde es más grande la brecha entre percepción de inseguridad y victimización?

```
brechas_departamentales <- indicadores_ultimo_anio |>
  mutate(
    brecha_percepcion_victimizacion = percepcion_al_caminar_de_noche -
      victimizacion
  ) |>
  arrange(desc(brecha_percepcion_victimizacion))

brechas_departamentales |>
  slice_max(brecha_percepcion_victimizacion, n = 12) |>
  ggplot(aes(
    x = brecha_percepcion_victimizacion,
    y = reorder(region_final, brecha_percepcion_victimizacion)
  )) +
  geom_col(fill = "#577590", width = 0.7) +
  geom_text(
    aes(label = number(brecha_percepcion_victimizacion, accuracy = 0.1)),
    hjust = -0.15,
    size = 3.2
  ) +
  labs(
    title = "Mayores brechas entre percepción y victimización",
    subtitle = glue("Diferencia en puntos porcentuales, {ultimo_anio}"),
    x = "Puntos porcentuales",
    y = NULL
  ) +
  tema_sesion()
```




La brecha resume una idea sustantiva: no toda inseguridad percibida proviene directamente de la victimización reciente. Medios, experiencias cercanas, deterioro urbano y confianza institucional pueden intervenir.

7. Cómo se calculan los indicadores

Antes de interpretar los resultados conviene abrir la caja negra: estos indicadores no están en la base como una sola variable lista para usar, sino que se construyen combinando filtros, factores de expansión y varias preguntas del cuestionario.

El flujo de trabajo tiene dos piezas. El script `procesar_enapres_mod600.R` lee los microdatos, calcula los indicadores y exporta archivos `.csv` y `.sav`. Este QMD usa los `.csv` para explicar, graficar y trabajar la inferencia; los `.sav` quedan disponibles para abrirlos y analizarlos directamente en SPSS.

La idea es la misma en SPSS y en R: primero se define el universo de análisis, luego se identifican las preguntas que forman cada indicador, después se crean variables binarias con valores 0 y 1, y finalmente se aplica el factor de expansión. La diferencia es que R permite convertir esa lógica en una función reutilizable para varios años.

La regla de lectura no es idéntica para todos los años. Entre 2010 y 2023 se trabaja con la estructura histórica del módulo de seguridad ciudadana; 2024 requiere un mapeo especial dentro del capítulo 600; y 2025 cambia con más fuerza porque pasa al capítulo 400. Por eso la serie se puede reconstruir completa, pero las comparaciones deben marcar esos cortes.

Paso del cálculo	Variables y etiquetas que se revisan	En SPSS	En R
Definir el universo de análisis: personas urbanas de 15 años a más, con entrevista válida y residencia habitual.	AREA área, RESFIN resultado final, P208_A edad, P204/P205/P206 residencia habitual.	COMPUTE filtro_enapres = (...) y luego IF o SELECT IF, según si se quiere conservar o filtrar la base.	mutate(filtro_general = AREA == 1 & RESFIN < 3 & P208_A >= 15 & ...).
Excluir omisiones del módulo o capítulo correspondiente.	P600_C en la serie histórica, P600B_C/P600C_C en 2024, P400_C/P400A_C en 2025.	IF (P600_C <> 99) filtro_modulo600 = 1.	mutate(valido_victimizacion = as.numeric(P600_C) != 99), adaptado por año.
Aplicar el factor de expansión correcto para estimar porcentajes poblacionales.	FACTOR, FACTOR600, FACTORANUAL; para algunos años se revisan factores específicos o calibrados.	WEIGHT BY FACTOR.	weighted.mean(indicador, w = peso) * 100.
Calcular victimización: si la persona reporta al menos un hecho delictivo.	P601_* en la serie histórica, P615_* en 2024, P424_* en 2025. Etiqueta: victimización.	COMPUTE victimizacion = ANY(1, P601_1, P601_2, ...).	row_any_equal(data, vars_victimizacion, 1).
Calcular percepción de inseguridad en los próximos 12 meses.	P611_1:P611_14 en la serie histórica; P601_* en 2024; P401/P402_* en 2025.	COMPUTE percepcion_12m = ANY(1, P611_1 TO P611_14).	row_any_equal(data, vars_percepcion_12m, 1).
Calcular percepción de inseguridad al caminar de noche.	P611A, P611B o P611B_1, según año; P604 en 2024; P405 en 2025.	IF (ANY(P611B_1, 1, 2)) percepcion_noche = 1.	case_when(!is.na(P611B_1) ~ indicador_en(P611B_1, c(1, 2)), ...).

Paso del cálculo	Variables y etiquetas que se revisan	En SPSS	En R
Calcular confianza en la PNP y delitos específicos usados en clase.	P608_1, P616A_1 o P409_1 para confianza; P601_6A/P601_6B, P615_9/P615_10, P424_9/P424_10 para robo o intento; P601_13, P615_21, P424_21 para estafa.	COMPUTE confianza_pnp = ANY(P608_1, 3, 4) y reglas similares para cada delito.	case_when() para escoger variables según año y indicador_en() para recodificar respuestas.
Guardar una base con indicadores calculados para seguir analizando.	Variables nuevas: victimizacion, percepcion_12m, percepcion_noche, confianza_pnp, estafa, entre otras.	SAVE OUTFILE = '.../enapres_2023_indicadores desde spss.sav'.	write_csv() y indicadores_from_spss() para guardar en carpeta resultados.

¿Cómo se ejecuta el script que procesa los .sav de seguridad ciudadana?

```
source(file.path(ruta_scripts, "procesar_enapres_mod600.R"))
```

El script exporta tres archivos en **resultados**: una base individual con indicadores, una tabla nacional y una tabla regional. Si luego se agregan nuevas bases de seguridad ciudadana, el mismo flujo puede volver a ejecutarse.

Además, la carpeta **scripts** incluye una sintaxis SPSS para 2023. Esa sintaxis calcula los indicadores dentro de una base ENAPRES específica, conserva las filas originales, agrega variables nuevas y guarda una copia .sav con los indicadores.

¿Qué resultados nacionales se obtienen al replicar los indicadores desde microdatos para toda la serie disponible?

```
archivo_micro_nacional <- file.path(
  ruta_resultados,
  "enapres_indicadores_nacionales.csv"
)

if (!file.exists(archivo_micro_nacional)) {
  stop(
    "Ejecuta primero el script procesar_enapres_mod600.R para crear los indicadores desde mi"
  )
}
```

```

}

micro_nacional <- read_csv(archivo_micro_nacional, show_col_types = FALSE)

micro_largo <- micro_nacional |>
  pivot_longer(
    cols = c(
      victimizacion,
      percepcion_12m,
      percepcion_noche,
      confianza_pnp,
      robo_intento_dinero_cartera_celular,
      estafa
    ),
    names_to = "indicador",
    values_to = "valor"
  ) |>
  mutate(
    indicador = recode(
      indicador,
      victimizacion = "Victimización",
      percepcion_12m = "Percepción próximos 12 meses",
      percepcion_noche = "Percepción al caminar de noche",
      confianza_pnp = "Confianza en la PNP",
      robo_intento_dinero_cartera_celular = "Robo o intento de robo",
      estafa = "Estafa"
    )
  ) |>
  filter(!is.na(valor))

etiquetas_micro_final <- micro_largo |>
  group_by(indicador) |>
  filter(anio == max(anio, na.rm = TRUE)) |>
  ungroup()

micro_largo |>
  ggplot(aes(
    x = anio,
    y = valor / 100,
    color = indicador,
    group = indicador
  )) +

```

```


geom_rect(
  data = etapas_enapres,
  aes(xmin = xmin, xmax = xmax, ymin = -Inf, ymax = Inf),
  inherit.aes = FALSE,
  fill = "#f1f3f5",
  alpha = 0.55
) +
geom_vline(
  data = cortes_enapres,
  aes(xintercept = anio),
  inherit.aes = FALSE,
  linetype = "dashed",
  color = "grey45",
  linewidth = 0.4
) +
geom_line(linewidth = 0.95, na.rm = TRUE) +
geom_text(
  data = etiquetas_micro_final,
  aes(label = percent(valor / 100, accuracy = 0.1)),
  hjust = -0.12,
  size = 2.9,
  show.legend = FALSE,
  na.rm = TRUE
) +
facet_wrap(~indicador, ncol = 2, scales = "free_y") +
scale_y_continuous(
  labels = percent_format(),
  expand = expansion(mult = c(0.08, 0.16))
) +
scale_x_continuous(
  breaks = seq(2010, 2025, by = 2),
  minor_breaks = NULL,
  expand = expansion(mult = c(0.03, 0.10))
) +
scale_color_paletteer_d("ggthemes::Tableau_10", guide = "none") +
labs(
  title = "Serie reconstruida desde microdatos ENAPRES, 2010-2025",
  subtitle = "Las líneas punteadas marcan cambios de estructura del cuestionario; las tend
  x = NULL,
  y = "Porcentaje"
) +
tema_sesion() +

```

```
theme(
  strip.text = element_text(face = "bold", size = 11),
  plot.title = element_text(size = 16),
  plot.subtitle = element_text(size = 11),
  panel.spacing = unit(1.1, "lines")
)
```

Serie reconstruida desde microdatos ENAPRES, 2010–2025

Las líneas punteadas marcan cambios de estructura del cuestionario; las tendencias son más comparables dentro de cada etapa.



La réplica desde microdatos permite mirar 2010-2025, pero no todos los tramos tienen la misma comparabilidad. El salto 2012-2013 y los rediseños de 2024-2025 deben leerse como cambios metodológicos además de posibles cambios reales en victimización, percepción o confianza.

¿Cómo debemos leer los cortes de la serie?

```
etapas_enapres |>
  transmute(
    etapa,
    lectura = c(
```

```

    "Útil para recuperar la trayectoria inicial, pero algunas variables todavía no están d
    "Tramo donde se consolida la medición reciente de varios indicadores; permite comparar
    "Tramo más estable para ejercicios de comparación temporal y territorial.",
    "Año de rediseño del capítulo 600; conviene validar cada indicador antes de unirlo mec
    "Año con cambio al capítulo 400; debe tratarse como una nueva etapa de medición."
  )
)

```

```

# A tibble: 5 x 2
  etapa                                lectura
  <chr>                                <chr>
1 2010-2012: estructura inicial        Útil para recuperar la trayectoria ini~
2 2013-2017: transición y estabilización Tramo donde se consolida la medición r~
3 2018-2023: serie comparable reciente Tramo más estable para ejercicios de c~
4 2024: rediseño del capítulo 600      Año de rediseño del capítulo 600; conv~
5 2025: cambio al capítulo 400         Año con cambio al capítulo 400; debe t~

```

8. Estimación e inferencia

Hasta aquí hemos descrito tendencias. Ahora damos un paso inferencial: usamos los microdatos y el factor de expansión para estimar porcentajes poblacionales, construir intervalos de confianza y explorar asociaciones entre variables.

Para esta parte trabajaremos con 2024. La razón es práctica: es un año reciente y todavía pertenece al capítulo 600. Aun así, 2024 ya no usa exactamente los mismos nombres de variables de la serie histórica: para victimización se usan preguntas P615_*, para percepción de los próximos 12 meses se usan preguntas P601_*, para percepción al caminar de noche se usa P604, y para algunos indicadores se aplican factores específicos del capítulo como FACTOR_CAP600B. El año 2025 puede analizarse también, pero debe leerse como una etapa distinta porque cambia al capítulo 400.

```

options(survey.lonely.psu = "adjust")

anio_inferencia <- 2024

base_inferencia <- micro_individual |>
  filter(anio == anio_inferencia) |>
  mutate(
    victimizacion = as.numeric(victimizacion),
    percepcion_12m = as.numeric(percepcion_12m),
    percepcion_noche = as.numeric(percepcion_noche),

```

```

    confianza_pnp = as.numeric(confianza_pnp),
    victimizacion_cat = factor(
      victimizacion,
      levels = c(0, 1),
      labels = c("No", "Sí")
    )
  )
)

diseno_victimizacion <- svydesign(
  ids = ~1,
  weights = ~peso_victimizacion,
  data = base_inferencia |>
    filter(!is.na(victimizacion), !is.na(peso_victimizacion))
)

diseno_percepcion <- svydesign(
  ids = ~1,
  weights = ~peso_percepcion,
  data = base_inferencia |>
    filter(!is.na(percepcion_12m), !is.na(peso_percepcion))
)

```

Estos diseños usan el factor de expansión. Para mantener la explicación en clase manejable, los intervalos se presentan como aproximaciones ponderadas; si se incorporan estratos y conglomerados completos, el cálculo de errores estándar puede afinarse.

¿Cuánto estimamos para los principales indicadores en 2024?

```

extraer_estimacion <- function(objeto, indicador) {
  tibble(
    indicador = indicador,
    estimacion = as.numeric(coef(objeto)),
    se = as.numeric(SE(objeto)),
    conf_bajo = confint(objeto)[1, 1],
    conf_alto = confint(objeto)[1, 2]
  )
}

estimaciones_inferencia <- bind_rows(
  extraer_estimacion(
    svymean(~victimizacion, diseno_victimizacion, na.rm = TRUE),
    "Victimización"
  )
)

```



```

),
extraer_estimacion(
  svymean(~percepcion_12m, diseno_percepcion, na.rm = TRUE),
  "Percepción próximos 12 meses"
),
extraer_estimacion(
  svymean(~percepcion_noche, diseno_percepcion, na.rm = TRUE),
  "Percepción al caminar de noche"
),
extraer_estimacion(
  svymean(~confianza_pnp, diseno_percepcion, na.rm = TRUE),
  "Confianza en la PNP"
)
) |>
mutate(across(c(estimacion, conf_bajo, conf_alto), ~ .x * 100))

estimaciones_inferencia

```

A tibble: 4 x 5

	indicador	estimacion	se	conf_bajo	conf_alto
	<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1	Victimización	28.0	0.00300	27.4	28.6
2	Percepción próximos 12 meses	85.2	0.00362	84.5	85.9
3	Percepción al caminar de noche	56.3	0.00535	55.2	57.3
4	Confianza en la PNP	21.7	0.00566	20.6	22.8

```


estimaciones_inferencia |>
ggplot(aes(x = estimacion / 100, y = reorder(indicador, estimacion))) +
geom_errorbar(
  aes(xmin = conf_bajo / 100, xmax = conf_alto / 100),
  width = 0.18,
  color = "grey45"
) +
geom_point(size = 3.2, color = "#3a86ff") +
geom_text(
  aes(label = percent(estimacion / 100, accuracy = 0.1)),
  hjust = -0.15,
  size = 3.3
) +
scale_x_continuous(
  labels = percent_format(),

```

```

limits = c(0, max(estimaciones_inferencia$conf_alto) / 100 * 1.15)
) +
labs(
  title = glue("Estimaciones ponderadas, {anio_inferencia}"),
  subtitle = "Barras: intervalos de confianza aproximados al 95%",
  x = "Porcentaje estimado",
  y = NULL
) +
tema_sesion()

```



El intervalo de confianza recuerda que no observamos a toda la población: estimamos un valor poblacional a partir de una muestra. El factor de expansión indica cuántas personas representa cada observación.

¿La victimización estimada cambia según sexo?

```

victimizacion_sexo <- svyby(
  ~victimizacion,
  ~sexo,
  diseno_victimizacion,

```

```

svymean,
vartype = "ci",
na.rm = TRUE
) |>
as_tibble() |>
mutate(across(c(victimizacion, ci_l, ci_u), ~ .x * 100))

victimizacion_sexo

```

```

# A tibble: 2 x 4
  sexo    victimizacion ci_l ci_u
<fct>      <dbl> <dbl> <dbl>
1 Hombre      30.4  29.5  31.3
2 Mujer       25.8  25.1  26.6

```


```

victimizacion_sexo |>
  ggplot(aes(x = victimizacion / 100, y = sexo)) +
  geom_errorbar(
    aes(xmin = ci_l / 100, xmax = ci_u / 100),
    width = 0.16,
    color = "grey45"
  ) +
  geom_point(size = 3.4, color = "#ef476f") +
  geom_text(
    aes(label = percent(victimizacion / 100, accuracy = 0.1)),
    hjust = -0.18,
    size = 3.4
  ) +
  scale_x_continuous(
    labels = percent_format(),
    limits = c(0, max(victimizacion_sexo$ci_u) / 100 * 1.18)
  ) +
  labs(
    title = glue("Victimización estimada según sexo, {anio_inferencia}"),
    subtitle = "Estimación ponderada con intervalo de confianza aproximado al 95%",
    x = "Victimización",
    y = NULL
  ) +
  tema_sesion()

```

Victimización estimada según sexo, 2024

Estimación ponderada con intervalo de confianza aproximado al 95%



El cruce por sexo permite pasar de una descripción general a una pregunta bivariada: si los intervalos se superponen mucho, la diferencia observada debe leerse con cautela.

¿La victimización estimada cambia según grupo de edad?

```
victimizacion_edad <- svyby(  
  ~victimizacion,  
  ~grupo_edad,  
  diseno_victimizacion,  
  svymean,  
  vartype = "ci",  
  na.rm = TRUE  
) |>  
  as_tibble() |>  
  filter(!is.na(grupo_edad)) |>  
  mutate(across(c(victimizacion, ci_l, ci_u), ~ .x * 100))  
  
victimizacion_edad
```


```
# A tibble: 4 x 4  
  grupo_edad victimizacion ci_l ci_u
```

	<fct>	<dbl>	<dbl>	<dbl>
1	15 a 24	32.7	31.4	34.0
2	25 a 39	34.4	33.2	35.6
3	40 a 59	28.2	27.1	29.2
4	60 a más	16.3	15.2	17.4

```
victimizacion_edad |>
  ggplot(aes(x = grupo_edad, y = victimizacion / 100, group = 1)) +
  geom_errorbar(
    aes(ymin = ci_l / 100, ymax = ci_u / 100),
    width = 0.12,
    color = "grey45"
  ) +
  geom_line(color = "#577590", linewidth = 0.9) +
  geom_point(size = 3.2, color = "#577590") +
  geom_text(
    aes(label = percent(victimizacion / 100, accuracy = 0.1)),
    vjust = -0.7,
    size = 3.3
  ) +
  scale_y_continuous(
    labels = percent_format(),
    limits = c(0, max(victimizacion_edad$ci_u) / 100 * 1.16)
  ) +
  labs(
    title = glue(
      "Victimización estimada según grupo de edad, {anio_inferencia}"
    ),
    subtitle = "Estimación ponderada con intervalo de confianza aproximado al 95%",
    x = "Grupo de edad",
    y = "Victimización"
  ) +
  tema_sesion()
```

Victimización estimada según grupo de edad, 2024

Estimación ponderada con intervalo de confianza aproximado al 95%



La edad introduce una variable categórica ordenada. Aquí la pregunta no es solo quién tiene el porcentaje más alto, sino si la diferencia entre grupos parece suficientemente clara para sostener una interpretación.

¿La asociación entre sexo y victimización es estadísticamente distinguible de cero?

```
prueba_sexo_victimizacion <- svychisq(  
  ~ sexo + victimizacion_cat,  
  diseno_victimizacion  
)  
  
prueba_sexo_victimizacion
```

Pearson's X^2 : Rao & Scott adjustment

```
data: svychisq(~sexo + victimizacion_cat, diseno_victimizacion)  
F = 57.947, ndf = 1, ddf = 62348, p-value = 2.731e-14
```

El resultado de la prueba de Rao-Scott sugiere que existe una asociación estadísticamente significativa entre sexo y victimización. En otras palabras, la proporción de personas victimizadas

no parece distribuirse igual entre hombres y mujeres. Esta asociación no implica causalidad; solo indica que ambas variables no se comportan como independientes en la muestra ponderada.

¿Qué pasa si modelamos la probabilidad de victimización con sexo y edad?

```
modelo_victimizacion <- svyglm(
  victimizacion ~ sexo + grupo_edad,
  design = diseno_victimizacion,
  family = quasibinomial()
)

tabla_modelo <- summary(modelo_victimizacion)$coefficients |>
  as.data.frame() |>
  rownames_to_column("termino") |>
  as_tibble() |>
  transmute(
    termino,
    estimacion_logit = Estimate,
    error_estandar = `Std. Error`,
    estadistico_t = `t value`,
    p_valor = `Pr(>|t|)`,
    razon_de_odds = exp(Estimate)
  )

tabla_modelo
```

```
# A tibble: 5 x 6
  termino      estimacion_logit error_estandar estadistico_t  p_valor razon_de_odds
  <chr>          <dbl>          <dbl>          <dbl>    <dbl>    <dbl>
1 (Interce~    -0.621          0.0331        -18.7  3.70e-78    0.538
2 sexoMujer    -0.216          0.0301        -7.17  7.33e-13    0.806
3 grupo_ed~    0.0865         0.0404         2.14  3.24e- 2    1.09
4 grupo_ed~   -0.202          0.0400        -5.04  4.57e- 7    0.817
5 grupo_ed~   -0.904          0.0511       -17.7  8.45e-70    0.405
```

El modelo logístico es una forma compacta de estudiar asociaciones multivariadas. La razón de odds mayor que 1 indica mayor probabilidad relativa frente al grupo de referencia; menor que 1 indica menor probabilidad relativa.

9. Ejercicios para seguir practicando

1. Repite la comparación entre victimización y confianza en la PNP para otro año.

2. Calcula la variación departamental entre 2019 y 2024 para un indicador.
3. Identifica tres departamentos con alta percepción y baja victimización.
4. Revisa la sintaxis SPSS y agrega un indicador adicional al script de R.
5. Cuando descargues nuevas bases de seguridad ciudadana, colócalas en **datos**, ejecuta el script y revisa si aparecen nuevas variables o cambios de nombres.

Estos ejercicios pueden apoyarse en el Posit Assistant de RStudio para revisar errores, pedir explicaciones de funciones y proponer mejoras al código.